

CloudCare AI 결측치 처리 시뮬레이션 문서

전제

이 문서는 실제로 결측치를 데이터에 주입하지 않은 상태에서 작성한 **시뮬레이션 문서**임. "만약 아래 방식으로 결측치를 만들었다면, 그걸 어떻게 처리했을 것인가"를 컬럼별로 미리 설계해둔 것.

최종 데이터(*_final.csv)에는 실제로 `days_since_last_qbr` 한 컬럼(4.7%)을 제외하고는 결측치가 없음. 이 문서에서 다루는 나머지 결측 시나리오는 전부 가상의 상황임.

왜 이 문서를 따로 만드는가

실제 B2B SaaS 데이터에는 시스템 장애, 초기 이력 부족, 미분류 필드 등으로 결측치가 여러 컬럼에 분산되어 나타나는 게 정상임. 하지만 지금 단계에서 실제로 결측치를 주입하면:

- 이미 검증까지 끝낸 4개 최종 테이블을 다시 만들어야 함
- 팀장님과 스케일링/전처리 방향을 아직 상의하지 않은 상태
- 실제로 결측 처리 스킬을 프로젝트에 반영할지 여부가 아직 미정

이런 이유로, 데이터는 지금 상태(결측치 사실상 없음)로 그대로 두고, **"결측치가 있었다면 어떻게 다뤘을 것인가"**를 설계 문서 형태로만 남겨서 나중에 팀 논의 후 실제 반영 여부를 결정하거나, 포트폴리오/면접 설명 자료로 쓸 수 있게 함.

결측치 3대 유형과 컬럼별 요약

결측치 처리법은 "왜 결측되었는지"에 따라 완전히 달라진다. 이 3대 유형을 먼저 구분해야 잘못된 방법(예: 무조건 평균대체)을 피할 수 있음.

유형	설명	잘못 처리하면 생기는 문제
MCAR (완전 무작위 결측)	결측 여부가 다른 어떤 변수와도 무관함 (시스템/파이프라인 장애가 대표적)	단순 삭제해도 편향은 없지만 정보 손실은 발생
MAR (관측 무작위 결측)	결측 여부가 "관측된 다른 변수"에 종속 (예: 계약기간이 짧아서 추이값 계산에 필요한 이력 부족)	단순평균대체 시 관측변수와의 관계가 왜곡됨
MNAR (비무작위 결측, 결측 자체가 정보)	결측된 값 자체의 특성 때문에 결측됨 (예: QBR을 한 번도 안 한 고객은 "마지막 QBR 날짜" 값이 아예 존재하지 않음)	통계적 대체(평균/중앙값)가 가짜 정보를 만들어냄

시뮬레이션 대상 컬럼 전체 요약

테이블	컬럼	가정한 유형	가정 결측율
customer_contract	company_size	MCAR	2~3%
monthly_cloud_usage	downtime_minutes	MCAR	1~2%
modeling_snapshot	cost_growth_3m, usage_change_3m	MAR (계약초기, 이력부족)	해당 조건 대 상자의 100%
modeling_snapshot	unresolved_ticket_rate, avg_resolution_hours	MAR (관측 window 내 티켓 0 건)	해당 조건 대 상자의 100%
modeling_snapshot	days_since_last_qbr	MNAR (QBR 이 력 없음)	이미 구현됨 — 4.7%

아래 상세 분석에서 테이블별/컬럼별로 이유와 처리법을 하나씩 다룬다.

컬럼별 상세 분석

1. company_size (customer_contract) — MCAR, 범주형

- **결측 시뮬레이션 가정:** 영업팀이 신규 리드를 CRM에 등록할 때 기업규모 분류를 누락하는 경우 (실제로 흔한 운영 이슈)
- **컬럼 특성:** 명목형 변수(Small/Medium/Large 등), 다른 변수(industry, 계약 규모)와 상관 있음
- **처리 후보와 평가**
 - 최빈값 대체: 가장 간단하지만 다수 범주로 실제 과소규모 고객을 오분류할 위험
 - **조건부(그룹별) 최빈값 대체** — 추천: annual_contract_value 구간별/industry별로 그룹을 나눈 뒤 그 그룹 내 최빈값으로 대체
 - 별도 범주 "Unknown" 추가 후 모델이 직접 학습하게 하는 방법도 타당

2. downtime_minutes (monthly_cloud_usage) — MCAR, 수치형(우편향)

- **결측 시뮬레이션 가정:** 모니터링 시스템 장애로 해당 월 다운타임이 기록되지 않은 경우
- **컬럼 특성:** 0이 많고 오른쪽으로 긴 꼬리가 있는 분포 (대부분 운영 안정 구간, 일부 장애 구간에서 급격히 치솟)

- 처리 후보와 평가

- 평균 대체: 와도 높은 값(장애월)가 희석해져 다운타임이 과소평가될 위험 — **부적합**
- 중앙값 대체: 치우치 영향 적지만, "장애 발생 자체"라는 정보를 지움
- **추천: 결측표시 플래그(`downtime_missing`) 생성 + 0 대체** — "기록 안 됨 = 장애가 없었을 가능성이 높다"는 도메인 가정이 통계적 대체보다 합리적이고, 플래그가 "이 값은 추정치"라는 정보를 모델에게 따로 전달

3. `cost_growth_3m`, `usage_change_3m` (modeling_snapshot) — MAR, 연속형(비율/차이)

- **결측 시뮬레이션 가정:** 계약기간이 짧아서(예: 6개월짜리 계약) D-60 시점까지의 관측window(6개월)를 충분히 확보 못해 prior 3개월 구간 데이터가 부족한 경우 (코드상 `prior_cost_avg > 0` 가드가 이미 있음 — 발동 조건만 열리면 됨)
- **컴럼 특성:** 기준점 대비 변화율/변화폭. 관측값이 없으면 개념상 "정의불가"한 값이지, "어떤 값으로 수렴하는" 값이 아님

- 처리 후보와 평가

- 전체 평균/중앙값 대체: **부적합** — "비용이 안 변했다(0%)"는 가정을 임의로 삽입하는 것이라 모델이 "이 고객은 안정적이다"로 잘못 학습할 수 있음
- **추천: 결측표시 플래그(`insufficient_history`) + 트리기반 모델(XGBoost/LightGBM)**
사용 시 **NaN 그대로 입력** — 트리 기반 모델은 결측치를 자체적으로 분기 기준으로 처리하므로 굳이 지워지 않아도 됨 (팀이 이미 XGBoost/LightGBM/CatBoost를 다루고 있으니 이 방법이 실제 적용하기 가장 맞음)
- 굳이 선형모델(로지스틱회귀 등)을 써야 한다면: KNN 대체(비슷한 `contract_term_months/company_size` 고객의 값으로 추정)가 차선택

4. `unresolved_ticket_rate`, `avg_resolution_hours` (modeling_snapshot) — MAR, 비율/평균형

- **결측 시뮬레이션 가정:** 관측window(6개월) 내 티켓이 0건이면 비율/평균 계산이 0으로 나뉘졌는지 않아 NaN (코드상 `total_tickets > 0`, `total_resolved > 0` 가드)
- **컴럼 특성:** 티켓이 적은 것 자체가 "운영이 안정적"이라는 긍정 신호일 수도 있어서 단순 결측이 아니라 "정보"로 해석할 여지가 있음

• 처리 후보와 평가

- `unresolved_ticket_rate`: 티켓이 0건이면 미해결도 0건이므로 **0으로 대체하는 게 도메인적으로 타당** ("티켓 없음 = 미해결 비율 0"이라는 해석이 합리적)
- `avg_resolution_hours`: 0으로 대체하면 "해결이 매우 빨랐다"로 오해될 수 있어 **부적합** — 전체 중앙값으로 대체하거나 NaN 그대로 유지(트리모델) 추천
- 둘 다 결측표시 플래그(`no_ticket_in_window`) 병용을 권장

5. `days_since_last_qbr` (`modeling_snapshot`) — MNAR, 이미 구현됨 (4.7%)

- **실제 상황**: 고객 전체 이력상 QBR(분기별 사업검토회의)을 한 번도 안 한 경우 NaN
- **컴럼 특성**: 숫값이지만 사실상 "QBR 이력 있음/없음"이라는 범주적 정보를 담고 있음(MNAR의 전형적 사례)
- **처리 후보와 평가**
 - 평균/중앙값 대체: **가장 나쁜 선택지** — "QBR을 한 번도 안 한 고객"을 "평균적으로 최근에 한 고객"으로 둔갑을지워버림(오히려 이탈 위험 신호일 수 있는데)
 - **추천: (1) `no_qbr_history` 이진 플래그 생성 (2) 결측값은 관찰 기간 내 최대값보다 큰 임의의 "sentinel" 값(예: 9999)으로 채우거나, 트리모델에게는 NaN 그대로 넘김** — 둘 다 "오래 안 했다/한 번도 안 했다"를 모델이 구별하게 해줌
 - **절대 하면 안 되는 것**: 평균이나 중앙값으로 채우는 것 — "언젠가 QBR을 했다"는 거짓 정보를 생성하게 됨

일반적인 결측치 처리 기법 비교

기법	적합한 상황	장점	단점
평균/중앙값 대체	MCAR, 분포가 좋고 결측율이 낮을 때	구현 간단, 빠름	분산이 인위적으로 줄어들, 치우치가 있으면 왜곡
최빈값 대체	범주형 MCAR	간단, 범주 유지	소수 범주 왕곡이 지워짐
조건부(그룹별) 대체	MAR, 관련변수가 몰람할 때	단순 대체보다 정확, 구현 비용 적당	그룹 기준을 잘못 잡으면 여전히 왜곡

기법	적합한 상황	장점	단점
KNN 대체	MAR, 비슷한 샘플로 추정할 때	여러 변수 관계를 반영, 정확도 높음	계산비용 큼, 거리척도 설계가 까다로운
MICE(반복적 회귀보간)	변수간 관계가 복잡하고 결측이 여러 컬럼에 분산되어 있을 때	통계적으로 가장 정교함	구현/해석 복잡, 과적합 위험
결측표시(indicator) + 상수 대체	MNAR, "결측 자체가 정보"일 때	결측 정보를 보존하면서 모델 학습 가능하게 만듦	컬럼 수가 늘어남
트리기반 모델 자체처리 (NaN 그대로 입력)	XGBoost/LightGBM/CatBoost 등 사용 시	별도 대체 작업 불필요, 결측 자체를 분기기준으로 학습	선형모델/다수 sklearn 모델은 지원 안 함
삭제 (listwise/pairwise)	결측율이 매우 낮고 MCAR일 때	가장 안전한 방법(편향 없음)	데이터 손실, 결측률이 높거나 MAR/MNAR이면 편향 발생

선택 기준 요약: 결측 유형(MCAR/MAR/MNAR)을 먼저 판단 → MNAR이면 "결측 자체가 정보"이므로 통계적 대체 절대 금지, 플래그+sentinel 또는 NaN 유지(트리모델) → MAR이면 관련변수 기준 조건부 대체 → MCAR이면 단순 대체도 큰 문제 없음.

최종 요약 및 실무 관점 코멘트

컬럼	추천 처리법
company_size	조건부(그룹별) 최빈값 대체
downtime_minutes	결측표시 플래그 + 0 대체
cost_growth_3m / usage_change_3m	추가 플래그 + 트리모델에서 NaN 그대로 입력
unresolved_ticket_rate	0 대체(티켓 0건=미해결도 0건)
avg_resolution_hours	트리모델 NaN 유지 또는 전체 중앙값
days_since_last_qbr	플래그 + sentinel값 (통계적 대체 절대 금지)

실무/포트폴리오 관점 코멘트

1. 팀이 이미 XGBoost/LightGBM/CatBoost를 다루고 있으니 (40_xgboost_lightgbm_catboost_titanic.md 참고), "결측치를 굳이 다 채우지 않고 트리모델이 직접 처리하게 함"이라는 선택지도 충분히 유효한 실무 방식임. "무조건 대체"가 정답이 아니라는 건 면접관이 좋아할 포인트임.
2. 면접에서 "결측치 어떻게 처리했나요" 질문이 나오면, 이 문서처럼 컬럼별로 결측 유형을 구분하고 근거를 대어 답변하는 것이, "평균으로 다 뺐다"라고 답하는 것보다 훨씬 설득력 있음.
3. 실제 데이터에 결측치를 넣을지 여부는 별개로, "넣지 않기로 했다면 왜/어떻게 처리했을 것인가"를 설계해둔 것 자체가 데이터 설계 역량을 보여주는 지향(portfolio artifact)이니, 팀장님과의 논의 결과와 무관하게 이 문서는 그대로 보관해둔 가치가 있음.

참고: "실무에서 보통 결측률이 몇 %"라는 업계 벤치마크 수치는 검증하지 못해 이 문서에 포함하지 않았음. 위 표의 가정 결측율(1~3%)도 범용적인 감각적 추정치임—실제 반영 시에는 팀과 협의해 조정 필요.