

CloudCare AI 데이터 정의서 (합성데이터 메타정보)

작성일: 2026-09-20 · 작성: @Someone

이 문서는 CloudCare AI 이탈예측 프로젝트에서 생성 중인 합성데이터 4개 테이블의 **컬럼별 의미**·**생성 로직**·**주의사항**을 팀원이 쉽게 이해할 수 있도록 정리한 데이터 정의서입니다. 각 테이블은 별도의 Python 스크립트로 생성되며, 스크립트 내부 주석에는 더 상세한 설계 근거가 적혀 있습니다.

0. 전체 그림 먼저 보기

데이터는 4단계로 이어지는 파이프라인 구조입니다.

1. **customer_contract** — "이 고객이 누구고, 어떤 계약을 맺었는가" (계약 단위 기본정보)
2. **monthly_cloud_usage** — 그 계약이 진행되는 동안 "매달 클라우드 비용과 사용량이 어땠는가"
3. **monthly_support** — 같은 기간 동안 "매달 기술지원(티켓, 미팅)이 어땠는가"
4. **modeling_snapshot** — 위 세 테이블을 계약종료 60일 전(D-60) 시점 기준으로 **한 계약당 한 줄**로 요약·집계한 것. 이게 실제로 머신러닝 모델에 넣을 최종 학습데이터입니다.

한 고객(customer_id)은 여러 번 계약을 갱신할 수 있어서, 여러 개의 contract_id를 가질 수 있습니다. (예: CUST_00000 고객이 1차 계약 후 갱신하면 CUST_00000_C1, CUST_00000_C2 두 개의 계약 레코드가 생깁니다.)

아직 없는 것: renewal_churn(실제로 이탈했는지 여부, Target)은 아직 계산되지 않았습니다. 이건 다음 단계에서 modeling_snapshot의 값들을 "입력"으로 써서 별도로 계산할 예정입니다. 지금 있는 4개 테이블은 전부 "이탈여부와 무관하게 관측 가능한 값"만 담고 있습니다.

1. customer_contract — 고객·계약 기본정보

한 행 = 한 번의 계약 건. 한 고객이 3번 갱신했으면 이 테이블에 4개 행이 생깁니다(최초 계약 + 갱신 3번).

컬럼명	의미
customer_id	고객(회사) 식별자. 여러 계약에 걸쳐 고정됨

컬럼명	의미
contract_id	계약 건 식별자 (customer_id + 계약순번)
contract_seq	이 고객의 몇 번째 계약인지 (1, 2, 3...)
industry	업종 (IT/제조업/유통 등 8개 카테고리)
company_size	기업규모 (1-4인/5-49인/50-299인/300인이상)
account_created_date	고객이 최초로 가입한 날짜. tenure 계산의 기준점
contract_start_date / contract_end_date	이번 계약의 시작일/종료일
contract_term_months	계약기간(개월). 12/24/36 중 하나
tenure_months	계약 시작 시점 기준 가입 후 경과 개월수
renewal_count	이 계약 이전까지 성공적으로 갱신한 횟수 (최초 계약이면 0)
managed_service_plan	관리형 클라우드 서비스 등급: Basic / Standard / Premium
support_plan	기술지원 등급: Standard / Priority / Enterprise

⚠ 아래 4개 컬럼은 이름이 _ (밑줄)로 시작하는 "내부 전용" 컬럼입니다. 다음 단계 데이터 생성용으로만 쓰이고, 최종 학습데이터에는 절대 들어가면 안 됩니다(모델이 답을 미리 알고 푸는 **leakage**가 됨).

컬럼명	의미
_baseline_monthly_cost_anchor	이 계약의 "기준" 월 비용. monthly_cloud_usage에서 실제 월별 비용을 만들 때 중심값으로 씀
_customer_satisfaction_latent	고객 만족도 (모델이 볼 수 없는 은닉변수, 0~1)
_budget_cut_prob	예산삭감이 일어날 확률적 성향 (은닉변수)
_competitor_pull	경쟁사 이탈 유인 정도 (은닉변수, 아직 코드에서 실제로는 사용 안 됨 - 향후 churn 계산 단계에서 활용 예정)
_org_change_flag	이 계약 주기에 조직개편 같은 이벤트가 있었는지 (0/1)

만든 근거: company_size 비중은 KOSIS(국가데이터처) 2023년 실측 통계로 검증했고, industry 비중·contract_term_months 분포·plan-support 상관관계는 팀이 아직 확정하지 않은 가정치입니다 (코드 주석에 [가정치] 로 표시되어 있음).

2. monthly_cloud_usage — 월별 클라우드 비용·사용량

한 행 = 한 계약의 특정 한 달. 예를 들어 12개월 계약이면 이 고객의 그 계약에 대해 12개 행이 생깁니다.

컬럼명	의미
contract_id, customer_id	어느 계약, 어느 고객의 기록인지
month_index	계약 시작 후 몇 번째 달인지 (1부터 시작)
month_date	그 달의 날짜
actual_monthly_cost	그 달에 실제로 청구된 클라우드 비용(원)
commitment_utilization_rate	사전에 약정한 사용량(commitment) 대비 실제로 얼마나 썼는지 비율. 1을 넘으면 약정량보다 더 많이 쓴 것(초과사용)
idle_resource_ratio	프로비저닝(할당)해둔 자원 중 실제로 안 쓰고 놓고 있는 비율
downtime_minutes	그 달에 발생한 장애(서비스 중단) 시간 (분)

만든 근거: 비용은 1단계에서 계산한 _baseline_monthly_cost_anchor 를 중심으로 매달 완만한 상승추세 + 노이즈를 더해 생성. utilization/idle/downtime/티켓 지표들은 "이 고객이 기술적으로 얼마나 건강한 상태인가"를 나타내는 하나의 공유 잠재변수(ops_latent)에 부분적으로 연동되도록 설계했습니다 — 그래서 이 지표들끼리는 서로 어느 정도 상관관계가 있지만 100% 종속은 아닙니다.

3. monthly_support — 월별 기술지원 이력

한 행 = 한 계약의 특정 한 달 (monthly_cloud_usage와 동일한 grain, 같은 month_index 기준으로 짝지을 수 있음)

컬럼명	의미
contract_id, customer_id, month_index, month_date	(monthly_cloud_usage와 동일)
ticket_count	그 달에 접수된 지원 티켓(문의/장애신고) 수
resolved_count	그 달 안에 해결된 티켓 수
unresolved_count	그 달 안에 해결되지 못한 티켓 수 (ticket_count = resolved_count + unresolved_count)
total_resolution_hours	그 달에 해결된 티켓들의 "해결까지 걸린 시간"을 다 더한 값. 평균 해결시간이 필요하면 $\text{total_resolution_hours} \div \text{resolved_count}$ 로 계산
had_qbr	그 달에 QBR(분기 사업 리뷰, 고객사와의 정기 점검 미팅)이 있었는지 (True/False)

만든 근거: 티켓 발생량은 ops_latent(운영 건강도)에 연동, 해결속도·미해결율은 support_plan 등급 (Standard/Priority/Enterprise)에 연동, QBR 주기는 support_plan별로 다르게 가정(Enterprise 3개월/Priority 4개월/Standard 6개월 - 근거자료 없는 업계 관행 가정치).

4. modeling_snapshot — 최종 학습데이터 (계약당 1행)

한 행 = 한 계약. 위 세 테이블을 "계약종료 60일 전(D-60) 시점" 기준으로, 그 직전 180일(≈6개월) 동안의 데이터를 요약·집계해서 만든 테이블입니다. **이게 실제로 모델 학습에 쓰일 테이블입니다.**

그대로 가져온 컬럼

컬럼명	의미
industry, company_size, managed_service_plan, support_plan, contract_term_months	customer_contract에서 그대로 가져온 값
tenure_months	주의: customer_contract의 tenure_months와 다름! 이걸 "D-60 시점" 기준으로 다시 계산한 값 (계약시작 시점 tenure + 그 사이 지난 개월수)

컬럼명	의미
renewal_count	customer_contract 값 그대로 (이 값은 계약 기간 중 안 바뀜)

이번 단계에서 새로 집계한 15개 Feature

컬럼명	의미	어떻게 집계했나
cloud_cost_30d	D-60 시점(가장 최근 달)의 월 비용	해당 월 값 그대로
cost_growth_3m	최근 3개월 평균 비용이 그 이전 3개월 평균 보다 얼마나 늘었는지(%)	$(\text{최근 3개월 평균} \div \text{이전 3개월 평균}) - 1$
budget_variance_pct	실제비용이 애초 "기준 비용" (_baseline_monthly_cost_anchor) 대비 몇 % 벗어났는지	$(\text{실제비용} - \text{기준비용}) / \text{기준비용} \times 100$
commitment_utilization_rate	최근 6개월간 평균 약정사용률	6개월 평균
usage_change_3m	약정사용률이 최근 3개월 vs 이전 3개월 사이 몇%p 변했는지	두 구간 평균의 차이 (%p)
idle_resource_ratio	최근 6개월간 평균 유휴자원 비율	6개월 평균
downtime_minutes_90d	최근 3개월(≈90일)간 장애시간 총합	3개월 합계
unresolved_ticket_rate	최근 6개월간 미해결티켓 비율	$(\text{6개월 미해결티켓 합}) / (\text{6개월 전체티켓 합})$
avg_resolution_hours	최근 6개월간 평균 해결시간	$(\text{6개월 총 해결시간}) / (\text{6개월 총 해결건 수})$

컬럼명	의미	어떻게 집계했나
days_since_last_qbr	가장 최근 QBR 이후 며칠이 지났는지	계약 시작부터 D-60 까지 전체 이력에서 가장 최근 QBR을 찾아서 계산. QBR을 한 번도 안 했으면 값이 비어있음(결측) - 이것도 의미있는 정보라 임의로 채우지 않았습니다. 전처리 때 결측치 처리가 필요합니다

보조변수 (Feature 아님 — 모델에 안 넣고 별도 활용)

컬럼명	의미
annual_contract_value (ACV)	연간 계약가치 추정치. $\text{cloud_cost_30d} \times 12 \times \text{plan 배수} \times \text{support 배수}$ 로 계산(배수는 아직 팀 미확정 가정치). 이탈확률과 곱해서 "놓치면 손해가 큰 고객"을 골라내는 용도로 씀 - 모델의 입력 feature로는 안 씀

⚠ 아직 남아있는 내부용 컬럼 (다음 단계에서 반드시 제거)

customer_contract에서 넘어온 은닉변수 4개(`_customer_satisfaction_latent` 등)가 아직 이 테이블에 그대로 있습니다. 다음 단계(renewal_churn 생성)에서 "입력"으로 쓰기 위해 임시로 남겨둔 것이고, 그 다음 단계(최종 leakage 제거)에서 반드시 지워질 예정입니다. **지금 이 파일로 바로 EDA나 모델링을 시작하면 안 됩니다.**

알아두면 좋은 이슈

- **budget_variance_pct**가 계약기간이 길수록 더 커지는 경향이 있음(12개월 평균 +3.7% → 36개월 평균 +14.6%). 이게 의도된 "사용량 자연증가" 신호인지, 아니면 두 feature가 중복정보가 되는 부작용인지 EDA 때 상관관계를 꼭 확인해봐야 함
- 계약간 managed_service_plan 유지율이 매우 높음(99%대) — 버그가 아니라 "비용구간 (bracket) 폭이 넓어서 웬만해선 안 바뀐다"는 설계상 자연스러운 결과로 확인됨(재검토 완료)

5. 앞으로 남은 단계

1. modeling_snapshot의 위 값들을 입력으로 **renewal_churn**(이탈여부) 확률 계산 및 샘플링
2. 첫 이탈이 발생한 계약 이후 이력은 잘라내기(truncate)
3.  로 시작하는 은닉변수 컬럼들을 전부 제거해서 **최종 학습데이터** 완성