

스마트 팩토리 강의 1 정리 — 카이스트 장영재 교수, "스마트"보다 "팩토리"가 먼저다

스마트 팩토리는 AI·IoT 같은 ICT 기술 자체가 아니라, 제조 시스템의 물류 흐름과 불확실성을 데이터 기반으로 이해해서 현명한 의사결정을 내릴 수 있는 능력이며, 이걸 가능하게 하는 4대 요소(제조시스템지식/자동화/연결화/지능화)와 제조의 근본 물리법칙(리틀의 법칙, 큐잉이론)을 먼저 알아야 진짜 스마트 팩토리를 만들 수 있다는 게 이 강의 시리즈 전체를 관통하는 메시지임.

다룬 내용 목록

- [0강] **인트로** — 강사 철학("정글로 가라"), 실제 산업 협업 사례 프리뷰(자동화시스템, 웅진케미칼, 마이크론, S중공업, AR/VR)
- [1강] **스마트 팩토리란 무엇인가** — 공장의 4M, 부가요소에서 핵심요소로의 변화, 스마트 시티 비유, 스마트 팩토리의 진짜 정의, 포크레인 비유, 왜 알아야 하나
- [2강] **스마트 팩토리의 핵심 요소** — 제조시스템지식/자동화/연결화/지능화 4요소, 자동화 vs 지능화 차이, 모라벡의 역설, 웨이퍼 불량 패턴/설비 이상징후/물류 혼잡 자율회피 사례
- [3강] **제조에서의 F=MA (Part1)** — 왜 과학(이론)이 필요한가, 파라마운트 레스토랑의 비밀, 리틀의 법칙($WIP=CT \times TH$), 놀이공원 비유, 반도체 30일 사례
- [4강] **제조에서의 F=MA (Part2)** — 큐잉이론(줄서기의 과학), 변동성과 대기시간의 관계, HP 잉크젯 프린터 생산라인 실패 사례, 단체 등산 비유
- [5강] **의사결정이 어려운 이유** — 메이저리그 자이언츠 사례, 카이스트 A/B제품 영업이익 최적화 사례, 의사결정이 어려운 3가지 이유, 데이터 라이프사이클, 정형/비정형 데이터 기반 의사결정 모델
- [6강] **AI와 스마트팩토리 (Part1)** — 왜 제조에 AI인가, 품질관리(비전/불량검출/GAN), 설비관리(사후정비→예방정비→상태기반→예지보전→예지보정), 디지털 장인
- [7강] **AI와 스마트팩토리 (Part2)** — 자동 반송 시스템(컨베이어/AGV/OHT), 자동화에서 자율화로, 강화학습과 알파고, 카이스트 vs 조지아텍 벤치마크, 마포대교 비유
- [8강] **디지털 트윈** — 정의, 스크린골프/내비게이션 비유, 시뮬레이션에서 디지털트윈으로의 진화, 5개 영화(기억 조작) 비유, AI+디지털트윈 실증사례, AR 활용

[0강] 인트로 — 강의 철학과 실제 사례 프리뷰

강의자료 상으로는 "0강"이 별도로 존재하는데, 음성 스크립트에는 이 부분이 따로 녹음되어 있지 않고 슬라이드만 있음(강사 소개 슬라이드 등은 1강 자료에도 중복으로 실려있어서, 1강 도입부에서 같이 설명했을 가능성이 높음). 슬라이드 내용만 정리하면:

강사의 철학

"사냥을 하려면 동물원이 아닌 정글로 가라!" — 현실 산업에 직접적인 기여가 없는 공학은 무의미하다.

이 철학을 뒷받침하는 예시로 라이트형제와 에디슨이 인용됨:

"라이트형제 첫 유인비행이 성공할 당시 항공학은 정립되지 않았으며, 에디슨이 전구를 발명할 당시에 전기/전자 공학도 존재하지 않았다."

즉 이론이 실무를 앞서가는 게 아니라, 실무 현장에서 문제를 풀다 보니 이론이 따라온다는 취지. 이 강의도 반도체 공장, 조선소, 화학공장 등 카이스트 연구진이 10년간 직접 겪은 현장 사례 중심으로 진행한다는 걸 예고하는 파트임.

실제 사례 프리뷰 슬라이드들 (사진만 있고 설명 텍스트는 없음 — 뒤 강의에서 하나씩 풀어서 다룸)


- 자동차 시스템 (카이스트 클린룸 자동대차 사진)
- 웅진 케미칼 (화학 플랜트 사진)
- 마이크론 사례 (반도체 장비 3D 모델 + 로그 데이터 시각화) → 6강에서 자세히 다룸
- S중공업 (조선소 야경 사진)
- AR/VR 활용 (VR 고글 착용 사진) → 8강에서 자세히 다룸
- "실제 사례 중심"이라는 문구로 이번 강의 시리즈 전체가 이론보다 실제 산업 프로젝트 경험 위주로 구성됨을 예고

 [원본 슬라이드 참고 — 웅진케미칼 화학플랜트 사진, S중공업 조선소 야경 사진, 마이크론 3D 장비 모델+로그데이터 시각화 사진. 팀 스터디용으로 캡처해두면 좋을 듯]

웅진 케미칼



마이크론 사례



S중공업



KAIST

Copyright © Young Jae JANG

6

ISysE
KAIST
Industrial & Systems Engineering

[1강] 스마트 팩토리란 무엇인가

도입 — "스마트"보다 "팩토리"

강의를 시작하면서 강사가 계속 강조하는 포인트: 많은 사람들이 "스마트 팩토리" 하면 "스마트" 쪽(센서, 데이터, AI)에만 관심을 갖고 "팩토리" 자체는 간과하는 경향이 있다는 것. 이 강의는 그 반대로, "팩토리"를 먼저 제대로 알아야 한다는 입장에서 시작함.

공장을 구성하는 4M

과거 공장 운영을 보는 관점은 아주 단순했음. 공장의 핵심 구성요소는 다음 4가지(4M)로 정리됨:

요소	영문	내용
사람	Man	우수한 기능공, 오퍼레이터
공정 프로세스	Method	어떻게 가공하는지, 어떤 반응을 일으키는지
가공품(원부자재)	Material	원재료, 로우 머티리얼
설비	Machine	기계

과거의 논리는 단순했음: **이 4개 요소를 각각 잘 관리하면 전체 공장이 잘 돌아간다.** 우수한 인력 + 우수한 프로세스 + 우수한 원부자재 + 좋은 설비 = 좋은 공장이라는 논리.

3개의 추가 요소 — 그리고 시너지 개념의 등장

1990년대 이후 IT 혁신이 일어나면서 공장 운영에 3가지 요소가 추가됨:

- 물류 자동화 설비** — 설비와 설비 사이에 사람이 옮기던 물건을 자동으로 옮기는 것. 그런데 강사가 강조하는 포인트는, 이게 단순히 "물리적으로 A에서 B로 옮기는" 문제가 아니라는 것. 마치 사람이 택시를 타고 이동할 때 "언제 출발해서 언제 도착하고, 버스로 갈까 택시로 갈까, 어느 시점에 환승할까"를 머릿속으로 그리는 것처럼, 자동 물류도 **어느 시점에 어떤 물건을 옮겨야 하는지 판단하는 "지능"**이 필요하다는 것. 즉 물리적 자동화 그 이상의 지능이 필요함.
- IT 시스템** — 공장 전체 운영의 "브레인" 역할. 현재 오더 현황, 어느 장비가 어느 시점에 무슨 일을 해야 하는지, 재고가 얼마나 있는지 등을 종합해서 판단하는 시스템.
- 데이터** — 장비-장비, 프로세스-프로세스가 서로 연결되며 발생하는 방대한 데이터.

중요한 포인트: 불과 몇 년 전까지만 해도 이 3가지는 "있으면 좋지만 없어도 그만인" **부가적 요소**로 여겨졌음. IT 시스템 없이도 엑셀로 관리하면 되고, 물류도 사람이 옮기면 되고, 데이터 분석 없이도 물건은 만들 수 있으니까. 하지만 IT/정보기술이 발달하면서 이제 이 3가지가 기존 4M을 "적극 지원"하면서 **상호 시너지**를 만들어내는 존재로 바뀌었음.

시너지 비유: 강사가 반복해서 강조하는 개념. 과거 "각자도생"의 세상에서는 각 요소가 100%씩 아무리 잘해도 전체 합이 300%가 안 되는 경우가 많았음(엇박자 때문에). 반면 서로 시너지를 내면 100% + 100% + 100%가 300%가 아니라 **400%, 500%**를 만들어낼 수 있다는 것. 즉 스마트 팩토리는 "각 요소를 따로 잘하는 것"이 아니라 **요소들이 유기적으로 연결되어 시너지를 내는 것**이 핵심.

📷 [원본 슬라이드 참고 — 나사(NASA) 우주왕복선 컨트롤센터 사진. 여러 시스템이 유기적으로 정보를 공유하며 시너지를 내는 모습의 비유로 사용됨]



스마트란 무엇인가 — 본질적 질문에 답할 수 있는 능력

강사가 정의하는 "스마트"의 핵심은 센서나 데이터 처리 같은 기술적인 것이 아니라 **공장 운영의 본질에 대한 질문에 답할 수 있는 능력**임. 구체적으로 다음과 같은 질문들:

- 왜 이 장비가 지금 이 작업을 하고 있는지 명확한 이유를 아는가?
- 공장 내 적정 재공(在工, WIP)이 왜 적절한지 설명할 수 있는가?
- 생산을 15% 증대하려면 어떤 장비가 병목이 될지 바로 산출할 수 있는가?
- 어제 발생한 수율 불량 문제의 구체적 원인이 무엇인가?
- 이 모든 질문을 데이터로 1시간 내에 설명할 수 있는가?
- CEO부터 현장 작업자까지 **같은 데이터, 같은 근거**로 상황을 파악하고 있는가?

마지막 항목이 특히 현업에서 자주 벌어지는 문제로 언급됨 — 사장이 보는 데이터와 현업이 보는 데이터의 기준이 서로 다른 경우가 많다는 것. 과거엔 데이터가 실시간으로 업데이트되지 않고 몇 달 전 데이터에 의존하는 경우가 많았지만, 이제는 클라우드 환경으로 실시간 공유가 가능해졌다는 점을 강조함.

강사의 결론: 이런 질문에 대해 "며칠 기다려야 분석이 됩니다"가 아니라 **즉각적으로 데이터 근거를 산출할 수 있는 인프라를 갖춘 것이 바로 "스마트"의 의미임.**

스마트 팩토리 설문조사 키워드 vs 본질

카이스트 연구진이 실제로 설문조사를 해보니 "스마트 팩토리" 하면 떠오르는 키워드로 4차 산업혁명, 디지털 트윈, IoT, 인공지능, 빅데이터, AR/VR, 5G, 클라우드 컴퓨팅 등이 나왔음. 모두 틀린 말은 아니지만, 강사는 이게 본질이 아니라고 강조함.

스마트 시티 비유

스마트 팩토리를 설명하기 전에 먼저 "스마트 시티"로 비유함. 세종시 스마트시티 예시를 들면서:

- AI 자율주행차가 거리를 활보하고
- IoT 장비가 24시간 미세먼지를 체크하고
- 스마트폰을 비추면 건물 정보가 나오고...

이런 첨단 기술이 다 갖춰져 있어도, 주차공간은 늘 부족해서 불법주차가 일상이고, 아이들이 안전하게 뛰어놀 공간은 없고, 상가 밀집지역엔 쓰레기가 산더미처럼 쌓여 악취가 진동한다면 — 이게 과연 스마트 시티일까? 답은 "아니다".

다시 스마트 팩토리로

같은 논리를 스마트 팩토리에 적용:

- AI 활용 AGV가 물류를 자동으로 반송하고
- IoT 장비가 설비 상태를 24시간 모니터링하고
- AR 장비로 작업자가 유지보수를 하고...

이런 첨단 ICT를 다 적용했음에도 제품 납기는 늘 들쭉날쭉하고, 품질 이상을 파악하는 데 몇 주가 걸리고, 안전사고는 늘 발생한다면 — 스마트 팩토리라고 할 수 없음.

스마트 팩토리의 진짜 정의

스마트 팩토리란 제조·투자·운영에 있어서 궁극적인 질문을 데이터 기반으로 답할 수 있는 능력, 그리고 현명한 최적의 의사결정을 내릴 수 있는 능력을 지원하는 것.

AI, 디지털 같은 ICT 기술들은 이걸 하기 위한 수단일 뿐이지, 그 자체가 목적이 되어서는 안 된다.

왜 스마트 팩토리를 알아야 하나 — 이유 1: 제조 시스템의 핵심을 안다는 것

스마트 팩토리를 안다는 것 = 제조 시스템의 핵심을 안다는 것. 여기서 "제조 시스템"이라는 단어가 처음 등장함. 과거엔 "제조를 안다"는 게 가공 기계 자체를 다루는 걸 의미했지만, 이제는 사람/프로세스/재료/IT시스템/데이터가 모두 조화롭게 돌아가는 하나의 운영 시스템을 아는 것으로 확장됨.

왜 스마트 팩토리를 알아야 하나 — 이유 2: 제조의 개념 자체가 진화 중

과거엔 제조 = "생산(공장)"만을 의미했지만, 이제는 설계 + 생산 + 공급사슬 + 서비스가 다 합쳐지는 개념으로 확장되고 있음. 이 배경은 디지털 혁신 — 과거엔 설계조직, 생산조직, 공급사슬조직이 관리 범위가 제한되어 따로따로 운영할 수밖에 없었지만, 이제 데이터가 통합되면서 조직 간 경계도 허물어지고 있다는 것.

예시(도요타 브레이크 사태로 추정) — 강사가 "2000년도? 2008년도인가?" 하며 언급한 사례: 생산된 자동차가 고장났을 때, 그 원인이 설계 문제인지 생산 문제인지 유통상 문제인지 고객이 잘못 사용한 건지 판별하기 어려운 상황에서, 각 조직이 각자의 KPI를 가지고 서로 "네가 잘못했다"며 책임을 떠넘기다가 원인 파악이 늦어져 큰 이슈로 번진 사례로 언급됨(스크립트 음성인식 상

"돌타, 브레이크 사태"로 나오는데 정확한 회사명은 원본 음성/자료로 재확인 필요 — 도요타의 2009~2010년경 대규모 리콜 사태를 지칭하는 것으로 추정됨 ⚠).

이제는 IT 시스템 발전으로 프로세스·데이터 통합이 이루어지면서, 자동차가 고장났을 때 운전자의 운전 습관 데이터(엑셀을 심하게 밟았는지, 극한 기후에 노출됐는지)나 공급업체 교체 시점과의 상관관계 등을 데이터로 추적해서 원인을 특정할 수 있게 됐다는 게 강사의 설명.

왜 스마트 팩토리를 알아야 하나 — 이유 3: 포크레인 비유 (기술의 영역이 아니라 리더십의 영역)

강사가 자주 인용하는 비유: **삽질로 토목공사를 하던 시대에 포크레인이 개발됨**. 포크레인 자체는 첨단 기술이라 많은 기업과 학생들이 "포크레인 기사가 되겠다", "포크레인을 사겠다"에만 몰두함. 하지만 **토목공사 프로세스 자체가 바뀌지 않으면 포크레인이 아무리 많고 기사가 많아도 무용지물**이라는 것. 포크레인이 있다면 일하는 방식 전체가 바뀌어야 하고, 이걸 가능하게 하려면 조직·프로세스·CEO의 명확한 의사결정 구도 자체가 바뀌어야 함.

스마트 팩토리도 마찬가지: 다양한 첨단 기술이 있어도, 기존 프로세스를 그대로 두고 기술만 끼워 맞추려 하면 아무 혁신도 안 일어남. 기술이 들어갈 프로세스를 새로 설계해야 하고, 역으로 "이 기술이 있으면 조직과 의사결정 구도를 어떻게 바꿔야 할까"를 고민하는 게 더 중요함. → **즉 스마트 팩토리는 기술의 영역이 아니라 리더십의 영역**이라는 게 강사의 결론.

본 과정에서 다루지 않는 것 / 다루는 것

- **다루지 않는 것**: 반도체 공정/프로세스 자체 설명, 세부 지식을 깊게 파는 것, 당장 실무에 바로 적용 가능한 테크닉
- **다루는 것**: 반도체(에 국한되지 않은) 제조 운영을 스마트하게 하기 위한 기초 지식, 다양한 지식들의 상호 상관관계 설명(향후 어떤 지식이 더 필요할지 방향 제시), 개념 이해를 통해 실무 적용을 고민할 수 있는 기회

강의 구성 예고: 제조 시스템의 이해, 생산 운영에서의 스마트한 의사결정, 설비관리 및 자동화 시스템, 첨단 디지털 기술(AI/디지털트윈/AR-VR)의 제조 활용.

[2강] 스마트 팩토리의 핵심 요소

4대 핵심 요소

이번 강의는 핵심 요소들의 **정의**와, 요소들 간의 **상호 상관관계**를 파악하는 데 집중함.

📷 [원본 슬라이드 참고 — "제조시스템지식"을 중심 원으로 두고 그 주변에 "자동화/연결화/지능화" 3개가 둘러싼 다이어그램. 이 강의 시리즈 전체를 관통하는 핵심 프레임워크 그림이라 꼭 캡처해둘 것]



1. 제조 시스템 지식 (Manufacturing System Knowledge) — 중심 요소
2. 자동화 (Automation)
3. 연결화 (Connectivity)
4. 지능화 (Intelligence)

① 제조 시스템 지식 — 제조에도 $F=MA$ 가 있다

강사가 물리학 비유를 씀: 물리를 배울 때 가장 먼저 배우는 게 뉴턴의 운동법칙($F=MA$)이듯, **제조 운영에도 이런 근본 법칙이 존재한다**는 것. 이 법칙(리틀의 법칙 등)을 무시하고 IT 시스템에만 집중하는 건 "어불성설"이라는 표현을 씀. 제조 시스템 지식은:

- 제조 물류 흐름에서의 불확실성 이해
- 재공(WIP), 사이클타임, 생산물의 상관관계 이해 (→ 3~4강에서 자세히 다룸, HP 사례 포함)

② 연결화 (Connectivity)

카이스트 연구진이 현업에서 스마트 팩토리 논의를 할 때 **가장 많이 듣는 말이 "연결"**이라고 함. 연결의 범위:

- 장비-장비, 프로세스-프로세스, 조직-조직, IT시스템-IT시스템 연결
- 장비-프로세스-조직을 아울러 조직운영/데이터/프로세스를 통합
- **부분 최적화가 아닌 전체 최적화**를 위한 상호 연결 (단순히 네트워크로 장비를 묶고 데이터를 보는 수준을 넘어, 조직·프로세스·

사람까지 유기적으로 연결된다는 개념)

- **실제현실-가상현실 연결** — 디지털 트윈, 사이버 피지컬 시스템과 같은 맥락 (8강에서 자세히 다룸)

③ 자동화 (Automation)

자동화의 3가지 영역:

1. **설비 제어 자동화** — 과거엔 사람이 온/오프 스위치, 가동/비가동을 하나하나 붙어서 조작했지만, 이제는 센서로 현상을 파악해 자동으로 온도를 조절하거나 절삭 가공을 제어함.
2. **물류 반송 자동화** — 설비와 설비 사이 물건을 옮기는 자동화. 카이스트 연구실에는 천장에 달린 자동대차와 자동 반송 AGV가 실제로 운영됨.
3. **사람의 인지 자동화** — 과거엔 사람이 눈으로 보고 소리를 듣고 직접 판단해야 했던 것을, 이제는 비정형 데이터(이미지, 소리)를 기반으로 자동 판독/인지는 것.

④ 지능화 (Intelligence) — 의사결정의 고도화

과거엔 생산 스케줄을 짜 때 선입선출, VIP 고객 우선 처리 같은 **사람이 만든 룰**로 처리했음. 하지만 공장이 복잡해지고 제품이 다양화되면서, "지금 이 장비에서 다른 제품으로 셋업 체인지를 하면 얼마나 걸리는지, 지금 오더 상황에서 어떤 제품을 어느 장비가 처리하는 게 최선인지" 같은 판단이 사람 머리로는 한계에 부딪힘. 지능화는 **사람이 판단하기 어려운 걸 컴퓨터/IT시스템이 대신 복잡한 논리연산으로 최적 판단하는 것**.

자동화 vs 지능화의 차이 — 그리고 모라벡의 역설

강사가 명확히 구분하는 포인트:

- **자동화** = 매뉴얼(수작업) 작업을 자동으로 대체 + 사람의 인지능력을 대체
- **지능화** = 사람이 판단하기 어려운 문제에 대한 최적 의사결정

타이어 불량 판독 사례: 카이스트가 국내 대표 타이어 업체와 협업하면서, 완성된 타이어가 불량인지 아닌지 판독하는 작업이 원래는 작업자가 매뉴얼로 하나하나 판독했는데, **판단 기준이 사람마다 조금씩 달라서** 불량 검출에 일관성 문제가 있었음. 이런 매뉴얼 작업을 기술로 대체하는 것이 **자동화**의 예.

즉석 암산 퀴즈 (382×56578): 강사가 청중에게 즉석 암산을 시키면서, "사람이 암산하기 어려운 이런 논리연산은 사실 이미 1950년대에 컴퓨터가 해결한 능력"이라고 언급. 반대로 불과 몇 년 전까지만 해도 글자도 모르는 어린애가 하는 "개 사진/고양이 사진 구별"은 컴퓨터가 못했음.

모라벡의 역설: 80년대 카네기멜론의 AI 학자 한스 모라벡(Hans Moravec)이 한 말:

"사람이 잘하는 것은 컴퓨터가 못하고, 컴퓨터가 잘하는 것은 사람이 못한다."


80년대엔 이게 맞았음(사람=인지, 컴퓨터=논리연산). 하지만 최근 딥러닝 기술로 컴퓨터의 인지능력도 좋아지면서 **모라벡의 역설이 깨지고 있다**는 게 강사의 설명. 그래서 최근엔 자동화(인지 대체)와 지능화(논리연산 기반 의사결정)를 "이건 자동화, 이건 지능화" 식으로 딱 잘라 구분하기 어렵고, 서로 겹치는 영역이 생기며 시너지를 낸다는 것.

 [원본 슬라이드 참고 — "자동화 vs 지능화 / 인지지능 vs 논리지능" 벤다이어그램. 자동화-지능화 원과 인지지능-논리지능 타원이 겹치는 그림으로, 개념 이해에 핵심적인 도식임]


- 사동화 vs. 시능화

AI? 지능화

- 인지지능 vs. 논리지능



단순한 웨이퍼의 불량 패턴 인지는 자동화
그러나 이러한 자동화를 기반으로 문제의 원인을
찾을 수 있다면 이는 지능화



KAIST

Copyright © Young Jae JANG

Q

ISusE


반도체 웨이퍼 불량 패턴 사례 — 자동화가 지능화로 확장되는 예

과거엔 웨이퍼 불량 패턴(동그란 웨이퍼 위에 불량이 어디 분포하는지)을 사람이 일일이 봤음. "이건 중간에 동그란 불량, 이건 스크래치 불량, 이건 모서리 불량" 식으로 사람이 눈으로 판독하던 작업이 이제는 **자동화**(이미지 인식으로 패턴 자동 판독)됨.

여기서 한 걸음 더 나아가는 게 **지능화**: 이 자동화된 패턴 인식 데이터를 설비 데이터, 로그 데이터와 매칭시키면, "특정 패턴의 불량은 어느 설비의 어떤 문제와 연관이 있다"는 것까지 유추할 수 있게 됨. 즉 단순 인지(자동화)에서 원인 추론(지능화)으로 발전.

 [원본 슬라이드 참고 — 6개의 원형 웨이퍼 맵(WBM 1~6)에 빨간 점으로 불량 패턴이 분포된 이미지. 중앙집중형/스크래치형/모서리형 등 패턴별로 다른 설비 문제를 시사한다는 설명의 핵심 시각자료]

단순한 웨이퍼의 불량 패턴 인지는 자!
그러나 이러한 자동화를 기반으로 문제
찾을 수 있다면 이는 지능화



설비 이상 징후 사전 판단 사례

강사 본인이 과거 반도체 장비 담당자로 일할 때 경험: 오래 설비를 관리하다 보면 "이 설비가 오늘 좀 이상하다"는 감이 생기는데, 과거엔 이런 감을 사람에게 의존할 수밖에 없었음. 이제는 데이터로 이런 감 자체를 자동화시키는 것. 이상 징후가 감지되면 과거 히스토리를 바탕으로 "몇 시간 후 고장날 수 있다"를 유추하고, 이를 통해 생산 스케줄을 재조정하는 것까지 가면 **지능화** 영역이 됨.

물류 혼잡 자율 해소 사례 (카이스트 상용화 솔루션)

반도체 공장의 물류 반송 시스템에서 물류가 한쪽에 몰리면 "교통 혼잡"처럼 되는 문제가 있음. 과거엔 사람이 계속 지켜보다가 "여기 너무 혼잡하다" 판단해서 경로를 수동으로 바꿔줬음. 카이스트가 개발한 시스템은 **혼잡을 스스로 인지하고, 스스로 풀어주는(우회시키는) 지능**까지 구현함. 이게 자동화에서 지능화로 넘어가는 대표 사례로 언급됨(7강에서 강화학습 기술로 더 자세히 다룸).

정리 — 시너지 사이클

자동화 시스템이 연결화를 통해 통합 환경을 구축하면 → 문제의 원인을 찾을 수 있고 → 연결된 시스템에서 부분 최적화가 아닌 **전체(시스템) 최적화**가 가능해지고 → 이게 지능화이며 → 전체 최적화를 통해 다시 제조 운영 효율이 올라가는 **선순환 구조**. 이 모든 게 제조 시스템 지식을 기반으로 돌아간다는 게 2강의 결론.

[3강] 제조에서의 F=MA (Part1) — 파라마운트 레스토랑의 비밀과 리틀의 법칙

왜 과학(이론)이 필요한가

강사는 "대포를 쏘서 목표물을 맞춘다"는 예시로 시작함. 이론 없이 이렇게 쏘보고 저렇게 쏘보면서 각도와 힘을 조정해 결국 맞출 수는 있지만, 그건 현명한 방법이 아님. **F=MA라는 물리학의 기본 원리를 알면 시행착오 없이 계산으로 답을 구할 수 있다는 것.**

자동차 설계, 전자공학도 마찬가지 논리 — 겉으로 보이는 복잡한 디테일 밑에는 항상 근본 원리(물리 법칙, 전기 기초 이론)가 깔려 있고, 그 위에 복잡한 시스템이 쌓이는 구조. **제조에도 이런 근본 이론이 있다는 게 이번 강의의 핵심 메시지.**

파라마운트 레스토랑의 비밀

미국 보스턴 다운타운에 위치한 작은 레스토랑 "파라마운트(Paramount)" 사례. 테이블이 딱 10개뿐인 이 조그마한 식당에서 아침 시간(오전 7시~11시) 동안 **300명이 식사**를 함. 어떻게 가능할까?

레스토랑 안에는 다음과 같은 안내문이 걸려 있음(강의자료에 영문 원문 인용됨):

"저희 음식점은 다른 식당과 달리 독특한 시스템으로 운영됩니다. 비록 협소한 공간에 적은 수의 테이블이 놓여있지만 신기하게도 손님들이 음식을 받아 테이블로 향하면 언제든지 빈 테이블을 찾을 수 있습니다. 어떤 원리가 저희 시스템을 가능케 하는지는 모르겠습니다. 하지만 이는 여러 방식을 시도하고 시행착오를 거쳐 발견한 성공적인 운영 방식입니다. 1937년부터 이 방식을 불편 없이 이용해오고 있습니다."

강사가 이 식당에 직접 자주 가봤다고 함 — 처음 갔을 때 사람이 너무 많아 깜짝 놀랐는데, 정작 줄을 서서 주문하고 음식을 받아 테이블로 가면 늘 빈 테이블이 있었다는 것.

비밀 풀이: 일반 식당의 시간 배분을 가정해보면(강의자료 기준):

- 음식 고르는 데 10분
- 웨이터 불러 주문하는데 5분
- 주문한 음식 기다리는데 10분
- **식사하는데 10분**
- 계산하는데 5분

→ **테이블을 차지하는 총 시간은 40분인데, 실제 식사 시간은 10분뿐.** 파라마운트의 비결은: 오픈키친 구조로 손님이 먼저 줄을 서서 **음식을 주문하고, 음식이 조리되는 과정을 구경하면서 줄을 지나가고,** 줄 끝에 도착할 때쯤 음식이 완성되어 계산 후 바로 테이블로 향하게 만든 것. 즉 "기다리는 시간"을 테이블이 아니라 **줄에서** 보내게 설계한 것. 그 결과 실제로 테이블을 쓰는 시간은 10분(식사시간)뿐임.

리틀의 법칙 (Little's Law)

이 파라마운트 사례를 수식으로 풀면:

$$WIP = CT \times TH$$

(재공 = 사이클타임 × 생산율/스루풋)

파라마운트 사례에 대입: 홀에서 식사하는 고객 수 = 식사시간 × 유입량

- 유입량: 4시간에 300명 → 분당 1.25명

- 식사시간: 10분

- → 홀에서 동시에 식사 중인 고객 수 = 1.25명/분 × 10분 = **12.5명 ≈ 10개 테이블로 커버 가능**

즉 정말로 10개 테이블로 300명을 처리하는 게 수학적으로 말이 되는 계산이었다는 것.

📷 [원본 슬라이드 참고 — 존 리틀(John Little) 교수 소개 슬라이드(강사와 함께 찍은 사진 포함). 존 리틀은 MIT 경영공학과 (OR센터)의 세계 최초 경영공학 박사]


존 리틀 (John Little)

John Little
Institute Professor
Professor of Marketing

Biography | Selected Publications



John Little has had a distinguished career spanning five decades. He has published seminal papers in operations research methodology, traffic signal control, decision support systems, and especially marketing. In operations research he is best known for his proof of the queuing formula $L = \lambda W$, commonly known as Little's Law. Considered a pioneer in marketing science, Little has done research on a broad set of modeling and decision support issues, including models of individual choice behavior, adaptive control of promotional spending, and marketing mix models for consumer packaged goods. He is co-editor with Blattberg and Glazer of *The Marketing Information Revolution*, HBS Press (1994). When the Internet burst on the scene, Little was quickly attracted to e-commerce and co-taught the first course on the subject at MIT Sloan. In addition to his continuing interest in consumer packaged goods, he is currently conducting research on marketing automation in Internet retailing. Among Little's honors, he has been elected to the National Academy of Engineering and has received the Parlin and Converse Awards of the American Marketing Association, as well as the Kimball Medal of the Institute for Operations Research and the Management Sciences (INFORMS). He is a Fellow of INFORMS and the American Association for the Advancement of Science.





Copyright © Young Jae JANG

27



놀이공원 비유

리틀의 법칙을 다른 예로 한 번 더 설명함. 에버랜드, 롯데월드 같은 놀이공원에서 롤러코스터, 회전목마, 브루라이드, 바이킹 등을 타는 계획을 세운다고 가정.

- 각 놀이기구 타는 시간: 5분씩 4개 = 20분

- 이동거리: 놀이기구 사이 이동 1분씩 3번 = 3분

- **합계: 23~24분**

그런데 이 23~24분을 1시간 안에 다 타는 게 가능할까? **거의 불가능**. 왜냐하면 아침 일찍 가도 이미 줄이 서 있고, 한 번 타고 오면 다음 곳도 줄이 서 있기 때문. 즉 **대부분의 시간을 "대기시간"에 허비하게 됨**.

이걸 제조 설비에 대입: 실제 제품이 가공되는 시간은 전체 시간에서 아주 일부분이고, 나머지는 이동하거나 대기하는 시간. **이 대기시간을 잘 활용하면 투입~산출까지의 시간을 획기적으로 줄일 수 있음**.

반도체 30일 사례: 반도체 메모리는 한 번 투입해서 나오는 데까지 약 **30일**이 걸림. 반도체 가격은 나날이 하락하는 특성이 있어서, 이 전체 시간을 하루나 이틀만 줄여도 엄청난 비용 절감 효과가 있다고 언급됨(강의자료에 실제 논문 — Robert C.

Leachman, Shengwei Ding, "Integration of speed economics into decision-making for manufacturing management", International Journal of Production Economics 인용됨).


재공(WIP)과 부채 비유: 놀이공원에 사람이 많다는 것 = 대기시간이 많다는 것 = 공장으로 치면 재공(Work-In-Progress, 투입됐지만 아직 완제품이 안 된 것)이 많다는 것. 투입된 물건이 가공되어 나오지 않으면 현금화가 안 되고, 이건 결국 **부채**나 마찬가지

지라는 게 강사의 비유. 재공을 오래 쥐고 있는 건 그만큼 낭비.


리틀의 법칙이 대단한 이유

이 이론($WIP = CT \times TH$)은 전체 공장의 생산 계획을 잡는 기본 이론이며, 물류라는 게 단순히 "A에서 B로 이동"만이 아니라 **이동 사이에 얼마나 많은 물건이 쌓여있는지, 그 이동을 어떻게 제어하는지가 전체 재공을 컨트롤하는 핵심**이라는 것. 이 법칙과 불확실성 원리를 함께 고려하면, "이 정도 설비와 불확실성이 있다면 이 정도 재공이 있는 게 당연하다"는 하나의 기준점(척도)을 산출할 수 있음. 실제 공장에 대입해서 "3일이면 될 걸 지금 재공이 200개여야 하는데 500개다"라는 식으로 비교율(문제 진단)을 낼 수 있다는 게 이 이론의 실용적 가치.

📷 [원본 슬라이드 참고 — "최적 이상 vs. 현실적 최악" 그래프 2개(TH-WIP 그래프, CT-WIP 그래프). 재공을 늘릴수록 생산율이 어떻게 변하는지, 사이클타임이 어떻게 변하는지 보여주는 곡선 — 리틀의 법칙을 시각적으로 이해하는 데 중요한 그림]



최적 이상 vs. 현실적 최악



NEW (강의자료 전용, 스크립트에는 없음) 강의자료에 "일본 단팥빵 공장" 영상을 보고 재공(WIP), 생산율(Throughput), 전체 사이클타임을 직접 유추해보는 실습 과제가 있었음(유튜브 링크 제공됨). 이 부분은 스크립트 음성에는 언급되지 않아 실제 강의 중 다뤘는지는 자료만으로는 확인 어려움.

[4강] 제조에서의 F=MA (Part2) — 큐잉 이론과 HP 사례

지난 강의 리뷰 및 이번 강의 목적

리틀의 법칙이 "큰 그림에서 전체 공장 운영을 설계하는 이론"이라면, **큐잉 이론(Queueing Theory)**은 각 단위 공정당 **현재 얼마나 대기시간이 있는지를 이해하는 이론**이라는 걸로 두 이론을 구분함. 이번 강의 목적은 제조 흐름을 제어하기 위한 기본 이론인 큐잉 이론 소개 + HP 사례 소개.

큐잉 이론이란 — "줄서기의 과학"

Queueing = 줄서기. 계산대에서 계산을 기다리거나 햄버거 가게에서 주문 후 기다리는 것처럼, **얼마나 기다릴지를 예측하거나 대기줄을 얼마나 크게 설계해야 하는지에 과학적 근거를 제공하는 이론**. 핵심 변수:

- **도착률**: 단위 시간당 몇 명이 오는가
- **서비스 타임**: 서비스(계산 등)에 걸리는 시간

이 둘의 상관관계로 대기 인원, 평균 대기시간을 계산함. 산업공학에서 주로 다루는 학문이고, 편의점 알바 몇 명을 고용해야 하는지, 공항 대기줄 공간을 얼마나 마련해야 하는지 같은 실무 계산에 쓰임.

편의점 계산대 예제 — 왜 "평균"만으로는 부족한가

사례 1: 10초에 한 명씩 정확하게 들어오고, 계산하는 데 정확히 10초 걸리는 경우 → 대기인원은 거의 없음(1명 수준). 딱딱 맞아 떨어지기 때문.

사례 2: 평균은 똑같이 10초에 한 명이지만, 실제로는 1초 간격으로 4명이 몰려 들어오고 그 다음 37초 동안 아무도 안 오는 패턴 ($1+1+1+37 = 40\text{초}/4\text{명} = \text{평균 } 10\text{초}$). 계산에 10초씩 걸린다고 하면, 뒤에 몰린 손님들은 **누적으로 계속 길게 기다려야 함**. 앞사람도 뒷사람도 결국 37초 가까이 기다리게 됨.


즉 **평균 도착률/서비스타임이 같아도, 도착시간과 서비스시간에 "변동성"이 있으면 대기시간은 기하급수적으로 길어질 수 있음**. 이게 큐잉 이론의 핵심 통찰.

 [원본 슬라이드 참고 — 편의점 사례2의 도착 간격·대기시간을 사람 아이콘과 숫자로 시각화한 슬라이드(37, 1,1,1 패턴 반복). 변동성이 대기시간에 미치는 영향을 직관적으로 보여주는 그림]

큐잉 예제

• 사례2 - 편의점 계산대

- 평균 10초에 한명씩 들어온다
 - 1초 간격으로 4명 이후 47초, $(1+1+1+37)/4 = 10$
- 편의점 알바가 계산하는데는 10초가 걸린다
- 대기 인원?



강의자료에는 큐잉이론의 수학적 근사식도 제시됨(변동계수 c_a , c_e 와 가동률 u 를 포함한 식) — 스크립트에서는 수식 자체를 자세히 풀어 설명하지 않고 "이 강의에서 구체적으로 다루는 시간은 아니다, 이런 이론이 있다는 것만 알면 된다"는 수준으로 넘어감.

공장 현장 적용: 장비가 놓고 있다고 해서 장비 처리 능력의 한계를 넘어서 계속 물건을 투입하면 대기줄이 확 길어지고, 한번 길어진 대기줄은 좀처럼 줄지 않음(오버타임 등으로 추가로 소진해야 함). 큐잉 이론을 기반으로 "이 정도 투입이면 이 정도 대기가 생길 것"을 예측해서 적절히 운영하는 "운영의 묘"가 필요하다는 게 강사의 설명. 단, 큐잉 이론은 어디까지나 **이론**이라서 실제 운영의 여러 변수를 다 담지 못하는 한계가 있고, 이 한계를 **데이터**로 보정하는 것이 "데이터 사이언스를 가장 적절하게 활용하는 방법"이라고 언급됨.

HP 잉크젯 프린터 사례

배경: HP가 잉크젯 프린터의 인기에 힘입어 신규 공장을 짓고 시장을 선점하는 전략을 세움. 월간 생산 목표는 **30만 대**. 당시 도요타의 린 매뉴팩처링(Lean Manufacturing) 개념을 도입해서, **공정과 공정 사이의 대기공간(버퍼)을 아예 다 없애버림** — 실제 가치를 만드는 가공 공정만 남기고 대기 공간을 제거한 "진정한 린 공장"을 지향한 것.

문제 발생: 실제 가동해보니 목표 30만 대의 **절반에도 못 미치는 실적**이 나옴. 원인 분석 과정:

- 각 장비를 개별로 테스트해보면 월 30만 대를 생산할 능력이 있었음
- 신설비다 보니 예측 못한 오작동(살짝 멈추고 사람이 와서 리셋)이 빈번하게 발생 → 이걸 감안해도 설비 단위로는 월 **29만 대** 수준
- 그런데 실제 공장 전체 가동 결과는 아무리 잘 돌려도 **12만 5천 대**밖에 안 나옴 — 미스터리였음


등산 비유로 원인 설명: 과거 등산 책자에는 "성인 남자 2명 + 여성 1명이 한 조를 이뤄 등산할 때" 기준 예상 시간이 적혀 있었음 (예: 홀로 등산 시 시속 1km). 그런데 **단체 등산**을 하면 사람마다 페이스가 다르고 쉬는 텀도 다르기 때문에, 가장 빠른 사람이 정상에 먼저 도착해도 그건 "완료"가 아님 — **모든 인원이 도착해야 완료**. 선두와 후미의 격차가 벌어질수록 선두는 계속 기다려야 하고, 페이스 빠른 사람도 지치게 되는 비효율이 발생함.

HP 사례에 대입: **개별 장비 하나는 29만 대 가능하지만**, 이런 장비가 100여 개 있으면 서로 손발이 안 맞을 때(변동성) **생산율이 기하급수적으로 떨어짐**. 이걸 각 장비의 생산율만 보고는 전체 시스템 결과를 유추할 수 없다는 것. 이 케이스는 실제로 **MIT의 스탠 거시인(Stanley Gershwin)** 교수가 프로젝트에 직접 참여해서 큐잉 이론으로 계산해봤더니 실제로 12만 5천 대 수준이라는


결론이 나왔다고 함(강의자료에 원논문 인용됨: Mitchell Burman, Stanley B. Gershwin, Curtis Suyematsu, "Hewlett-Packard Uses Operations Research to Improve the Design of a Printer Production Line", *Interfaces* 28: Jan-Feb 1998, pp. 24-36).

해결책: 각 장비 사이에 **적절한 버퍼(재공 공간)**를 다시 만들어주는 것. 어느 한 장비가 멈추더라도 다른 장비는 버퍼에 있는 재공으로 계속 작업할 수 있어서 영향이 사방으로 퍼지지 않게 함. 즉 **버퍼가 너무 많은 것도 안 좋지만, 버퍼가 전혀 없는 것도 문제**라는 게 핵심 교훈 — 버퍼가 없으면 100개 장비 중 하나만 서도 전체가 다 서게 됨.

 [원본 슬라이드 참고 — "버퍼공간 제거" 슬라이드(No limit / Little bit of limit / HP case-no buffer 3단계 비교 그림), "생산량과 버퍼" 그래프(가동율 P vs 버퍼 크기 k, capacity loss 곡선). HP 사례의 핵심 원리를 시각적으로 보여주는 그림들]



• 머퍼의 당과 생산당



$$P = \min_i \left\{ \frac{1}{T} \frac{MTTF_i}{MTTF_i + MTTR_i} \right\}$$

$$P = \frac{1}{T} \frac{1}{1 + \sum_{i=1}^k \frac{MTTR_i}{MTTF_i}}$$

KAIST

HP 시사점


제조 운영의 기본 법칙을 알아야 한다. 이런 기본적인 이론 이해가 없으면 스마트 팩토리는 불가능하다.

강의자료에는 시스템 모델링 비유 그림도 있음 — 웨이퍼 투입량(Wafer Start Quantity)이 병목 공정(Bottleneck WS)을 거쳐 목표 산출량(Target Output Quantity)과 실제 산출량(Actual Output Quantity) 사이에 차이가 생기는 걸 물통 비유로 표현한 그림.

[원본 슬라이드 참고 — 웨이퍼 투입량이 여러 공정 물통을 거쳐 최종 산출량이 나오는 "물통(밸브)" 비유 다이어그램. 병목공정 WIP, 비병목공정 자재, 목표산출량 vs 실제산출량을 시각화]

비유

- System modeling



[5강] 의사결정이 어려운 이유

반도체 팹 운영에서의 실제 의사결정들

강의를 여는 질문들 — 실제로 공장 운영자가 매일 마주하는 의사결정:

- 계획된 물량을 생산하려면 어떤 장비가 언제 입고돼야 하는가?
- 생산성을 최대화하려면 어떤 장비가 어떤 작업을 해야 하는가?
- 공정 내 최적 WIP 프로파일은?
- 지금 유지보수를 해야 하나, 다음 주에 해도 괜찮을까?
- 어제 발생한 수율 문제의 원인은 무엇인가?

스마트 팩토리 = 스마트 의사결정. 데이터와 시스템에 의한 명확한 의사결정이 핵심.

메이저리그 자이언츠 사례 — "가능성"의 함정

1996년 가을, 당시 내셔널리그 서부지구 4팀 순위(강의자료 표 기준):

팀	승	패	남은경기
LA 다저스	78	63	21
샌디에이고 파드리스	78	65	19
콜로라도 로키스	71	71	20
샌프란시스코 자이언츠	59	81	22

당시 한 해설자가 "자이언츠가 꼴찌지만, 남은 22경기를 다 이기면 81승 81패가 되고, 다저스가 남은 경기를 다 지면 78승에 머무르니 1위 진출 가능성이 있다"는 코멘트를 함.

하지만 이견 틀린 논리. 메이저리그는 무승부가 없고(승/패만 존재), 리그 내에서 진행되는 경기이기 때문에 **한 팀이 이기면 다른 한 팀은 반드시 진다**는 제약조건이 있음. 즉 "자이언츠가 다 이기고 다저스가 다 진다"는 단순 가정만으로는 실제 가능성을 판단할 수 없고, 남은 경기가 어느 팀과의 대전인지까지 함께 고려해야 함.

미국 UC버클리 학생들이 이걸 실제 최적화 수식(정수계획법 형태)으로 계산해봤더니, 이 라디오 코멘트가 나온 시점에 이미 **자이언츠는 며칠 전에 수학적으로 탈락이 확정된 상태**였음. 심지어 자이언츠 구단 스스로도 이 사실을 모르고 있었다고 함.

시사점: 사람은 복잡한 상황을 다 고려하기 어려워서 단순하고 직관적으로 판단하는 경향이 있고, 이런 단순한 판단이 쌓이면 전 체계적으로 큰 비효율을 만들어낸다는 것.

카이스트 A/B 제품 영업이익 최적화 사례

카이스트가 실제 산업과제에서 겪은 유사한 경험. 단순화한 예시:

- **A제품**(일반 제품): 영업마진 약 **4만 5천원**

- **B제품**(프리미엄 제품): 영업마진 약 **6만원**

상식적으로 생각하면 "마진이 높은 B를 최대한 많이 만들고 남는 시간에 A를 만드는 게 낫다"고 판단하기 쉬움. 하지만 실제로는 여러 공정(A, B, C, D 등)에서 각 제품을 가공하는 데 필요한 시간이 다 다르기 때문에, 이런 공정별 소요시간과 가용시간을 전부 고려하면 단순히 "B를 최대한 많이"가 오히려 비효율적이었음.

카이스트 팀이 실제로 공정을 고려한 최적 조합을 다시 계산한 결과, 기존 방식 대비 **영업이익을 약 9.5%(강의자료 기준 표기, 스크립트 음성상 "10% 정도"로 언급) 더 올릴 수 있는 방법**을 찾아냄. ⚠ 스크립트에서는 "9.5% 정도, 근한 10%"로 다소 뭉뚱그려 언급했고, 강의자료 슬라이드에는 손글씨로 "9.5% 영업이익"이라고 표기되어 있어 정확한 수치는 9.5%로 보임.

의사결정이 어려운 3가지 이유

1. **정보의 부재** — 의사결정에 필요한 정보 자체가 없음 → 해결: 빅데이터, IoT, AR/MR로 정보 수집 인프라 구축
2. **복잡성** — 정보가 있어도 고려해야 할 관계가 너무 많아 사람 머리로 처리하기 어려움 (위 두 사례가 이 케이스) → 해결: 인공지능, 디지털 트윈, 클라우드 컴퓨팅, IoT, 5G로 계산/시뮬레이션 지원
3. **예상치 못한 일의 발생** — 아무리 잘 계획해도 환경이 바뀌어버리면 계획이 무력화됨

데이터 전 주기 (Data Lifetime Cycle)

데이터 수집 → 지식 발견(Knowledge Discovery) → 의사결정 지원(Decision Supporting)의 3단계 구조:

- 데이터 수집(Data Acquisition): 센서, 스마트 디바이스, 개인 디바이스, 소셜 데이터
- 지식 발견: 데이터마이닝, 통계분석, 데이터 관리
- 의사결정 지원: 수학적 모델링 + 최적화 + 시스템 설계 (+ 도메인 지식)

예시: 데이터를 모아보니 "이 장비는 평균 10시간 가동하면 불안해지기 시작한다"는 인사이트를 얻으면(지식 발견 단계), 이걸 바탕으로 "그럼 이 장비는 지금 세우고 다른 장비에 일을 맡기자"는 한 단계 더 나아간 **의사결정**을 내리는 게 진짜 핵심이라는 것.

사람-기계의 의사결정 공존 구조

- **기존 개념**: 데이터 수집 → 데이터 분석 → 결정/판단은 **사람**이 함
- **스마트 팩토리 패러다임**: 데이터 수집 → 데이터 분석 → **알고리즘 기반 결정/판단**까지 IT 시스템이 담당

사람의 역할이 바뀜: 인사이트를 기반으로 알고리즘이 의사결정을 할 수 있도록 **설계**하고, 알고리즘의 판단을 이해하고 운영할 수 있는 지식을 갖추는 것.

정형 데이터 기반 의사결정 — 수학적 모델링 사례

전통적인 모델 기반 의사결정은 정형 데이터를 바탕으로 사람이 만든 룰/수학적 모델로 판단함. 카이스트가 실제로 수행한 사례들  (강의자료 위주, 스크립트에도 개괄 언급):

1. 위에서 설명한 **A/B 제품 생산 비중 최적화** 사례
2. **생산 거점 위치 결정** — 국내 스마트폰 생산기업 사례. 기존 상식·관행에 근거한 물류 설계 비용은 950억원이었는데, 카이스트 팀이 제안한 데이터 기반 물류 설계로 **700억원, 약 26% 비용 절감**
3. **WIP 최적화 및 스케줄링 최적화** — 혼합정수계획법(Mixed Integer Programming)을 활용한 목표 생산을 위한 장비 대수 산정

 [원본 슬라이드 참고 — 국내 지도에 기흥/천안/구미/여수 등 생산거점 후보를 표시한 생산거점 최적화 사례 지도. 실제 비용 절감 수치(26%)와 함께 임팩트를 보여주는 그림]

사결정 - 사례

• 직관적인 선택 방식



12

ISUSE

비정형 데이터 기반 의사결정 — 감(느낌)을 기계가 대신하기

정형 데이터로는 풀기 어려운 "사람이 감으로 판단하는" 영역들:

- 설비 이상 감지: "완전 고장"처럼 명확한 경우 말고, "오늘 뭔가 좀 이상한 것 같다"는 애매한 감
- 물류 혼잡 판단: "특정 구역에 물류가 30개 있으면 정상, 50개면 혼잡"이라 하면 "왜 49개는 혼잡이 아니고 50개는 혼잡인가?"라는 애매함이 항상 존재


과거엔 이런 비정형적 판단은 정형화하기 어려웠지만, 이제는 학습을 통해 사람의 인지를 습득해서 감을 기계에 의하게 하는 방식이 발전 중.

적용 사례: OHT/AGV 제어(카이스트가 개발, Q-Learning 기반 알고리즘, 2017년), 물류 혼잡을 스스로 감지하고 우회하는 지능형 시스템, Stocker 시스템의 자율 제어 등 (→ 7강에서 강화학습으로 자세히 다룸)

📷 [원본 슬라이드 참고 — "결정-판단의 기술에서의 AI발전" 다이어그램. 정형데이터→컴퓨터인지→수학적모델링(사람이 만든 룰) 경로와, 비정형데이터→사람인지→사람판단 경로가 나란히 있다가, 비정형데이터 인지·판단도 컴퓨터가 담당하는 방향으로 화살표가 진화하는 걸 보여주는 그림. AI가 어디를 대체하고 있는지 한눈에 보여주는 핵심 도식]

결정-판단의 기술에서의 AI발전

• 전통적인 모델 기반



[6강] AI와 스마트 팩토리 (Part1) — 품질관리와 예지보전


왜 제조에 AI가 필요한가

요즘 AI = 데이터 기반 기계학습. 강사가 80년대 AI를 배운 사람이라면 룰 기반의 "전문가 시스템(Expert System)"을 떠올릴 거라고 언급 — 당시엔 논리적 규칙을 사람이 짜넣는 방식의 AI가 유행했지만, 이제는 **데이터를 통해 기계가 스스로 학습해서 사람의 의사결정을 모사하는** 방식이 주류가 됨.

제조에 AI가 필요한 3가지 배경:

1. **데이터 증가** — IT 시스템을 통해 지속적으로 데이터가 유입됨
2. **제조 특성상 정의하기 힘든 부분이 많음** — 물류의 혼잡, 장비의 불안정함, 품질 문제 등은 사람이 "감"으로는 판단해도 명확한 논리적 기준을 말로 설명하기 어려움 (개/고양이 사진 구별처럼 — 구별은 쉽게 하지만 차이를 논리적으로 설명하긴 어려움)
3. **비정형 데이터** — 소리, 사진, 로그데이터 같은 것들을 다루는 기술이 최근에서야 발전함

📷 [원본 슬라이드 참고 — AI/Machine Learning/Supervised·Unsupervised·Reinforcement Learning/Deep Learning의 포함관계를 보여주는 벤다이어그램. AI 용어 체계를 정리하는 데 유용한 기본 그림]



AI 학습 방식 3가지

- **지도학습(Supervised Learning):** 정답(레이블)이 있는 데이터로 학습. 예: 개 사진에 "개"라는 정답이 붙어있는 데이터로 패턴을 학습
- **비지도학습(Unsupervised Learning):** 정답 없이 데이터 구조만 보고 판단
- **강화학습(Reinforcement Learning):** 데이터 없이 시행착오(trial and error)로 학습하며, 알파고로 유명해진 방식 (→ 7강에서 자세히)

제조 AI 활용 3대 분야

강의자료의 핵심 프레임워크 **NEW**:

분야	기술
품질관리 (Quality Control)	Computational auditory scene analysis(CASA), CNN+RNN
설비관리 (Preventive Maintenance)	CNN-GAN-RNN 기반 가짜 이상신호 재생성
자율운영 (Autonomous Operation)	강화학습 + CNN

이 세 분야 모두의 기반에는 **제조 도메인 지식**(현장 "경험", 문제정의, 시스템적 사고)이 필수적으로 깔려 있어야 한다는 게 강사가 강조하는 부분. 실제로 카이스트에 프로젝트 문의가 들어오는 기업들 중 상당수가 "데이터 분석을 1년 동안 이것저것 해봤는데 아무 소득이 없었다"는 경우였는데, 그 이유가 **제조 도메인 특성을 모르고 데이터 분석에만 덩벼서**라는 게 강사의 진단. AI 기술만으로는 부족하고 제조 자체의 지식이 함께 융합돼야 한다는 것.

품질관리 — 비전(Vision) 기반 불량 검출

가장 흔하고 많이 쓰이는 AI 활용 분야는 **비전 기반 불량 검출**. 이미지 처리 → 특징 추출(Feature extraction) → 검출/분류(Detection and classification) → 최종 판단(Final decision)의 파이프라인.

웨이퍼 불량 패턴 분류(Wafer defect classification): 2강에서 다룬 그 웨이퍼 맵 사례를 카이스트가 실제로 알고리즘화한 것.

GAN을 활용한 불량 데이터 생성: 품질관리 AI의 가장 큰 난제 중 하나는 **불량 데이터가 절대적으로 부족**하다는 점 — 일반 공장에서 정품 999개당 불량 1개 수준으로, 학습에 쓸 불량 데이터 자체가 희소함(마치 개/고양이 사진 학습 시 개 사진은 많은데 고양이 사진이 거의 없는 상황과 비슷). 과거엔 사람이 임의로 불량 이미지를 랜덤하게 만들어봤지만 효과가 별로였음. 이제는 **생성적 적대 신경망(GANs)**을 활용해 불량 패턴을 학습하고, 가짜 불량 데이터를 대량 생성("뽕튀기")해서 불량/정품 구별 학습에 사용하는 기술이 발전 중. 강의자료에는 실존하지 않는 사람 얼굴을 GAN으로 생성한 유명한 사례(2020년 12월 뉴욕타임즈 기사 인용) **NEW** 도 예시로 제시됨.

설비관리(Maintenance) — 5단계 발전

강의자료 기준 설비 유지보수의 발전 단계 **NEW**:


1. **사후정비(Corrective Maintenance)** — 고장나면 그때 고침. 예상 못한 고장에 많은 리소스가 급하게 투입돼야 하고 원인 파악도 나중에 해야 해서 비효율적
2. **예방정비(Preventive Maintenance)** — 일주일에 한 번, 한 달에 한 번 식으로 시간을 정해놓고 정기적으로 정비. 화학공장은 1년에 한 번 전체 설비를 세우고 완전히 해체·재조립하기도 함. 하지만 이것도 최선은 아님 — 실제로 2~3년에 한 번 고장나는 설비를 매번 세워서 점검하는 건 비효율
3. **상태기반 진단(Condition Based Maintenance)** — 데이터를 뽑아서 "지금 불안정하다"는 상태를 보고 정비 시점을 결정(SPC, 6-시그마 기법 활용). 센서/데이터처리 비용이 줄면서 최근 활성화되는 중
4. **예지보전(Predictive Maintenance)** — 데이터 패턴을 보고 "이런 패턴으로 가면 다음달에 문제가 생길 수 있다"를 예측해서 미리 세워두는 것(Prognostic and health management, trend analysis 등)
5. **예지보정(Predictive Process Adjustment)** — 여기서 한 걸음 더 나아가 **스스로 알아서 보정**까지 하는 것. 예시: 가정용 레이저 프린터가 쓰지도 않았는데 갑자기 혼자 웅 하고 돌아가는 경우 — 내부적으로 노즐이 막힐 것 같다는 데이터를 보고 알아서 노즐을 청소하는 액션을 취하는 것

비정형 데이터 활용 — 소리, 진동, 로그 데이터

소리 → 스펙트로그램 변환: 음향/소리 데이터를 스펙트로그램(이미지)으로 변환해서 CNN으로 학습하는 방식이 발전 중(강의자료의 Raw-DCNN + Spectrogram-DCNN + Joint Tuning Layers 구조).

Visual Augmentation(모션 증폭): 기계학습 기술은 아니지만 픽셀 단위로 미세한 움직임(진동)을 증폭시키는 디지털타이즈 기술. 사람 눈으로는 전혀 떨림이 안 보이는 설비도, 각 픽셀의 움직임 벡터를 증폭하면 카메라 상으로 엄청난 떨림이 보이게 됨 — 이를 통해 "구조적으로 어느 부분이 취약한지", "나사가 빨리 풀릴 것 같은 부위가 어딘지"를 파악해서 센서 설치 위치나 정비 주기를 결정하는 데 활용됨.

📷 [원본 슬라이드 참고 — "Visual Augmentation" 슬라이드의 Standard HD Video vs Enhanced Motion Amplification Video 비교 이미지. 같은 설비를 찍은 영상인데 증폭 버전에서만 진동이 뚜렷이 보이는 대조가 인상적인 자료]



12

마이크론 빅데이터 프로젝트 사례

카이스트가 마이크론과 함께한 실제 프로젝트 **NEW** (0강 프리뷰에서 언급했던 사례):


- **목표:** 장비 내부 웨이퍼 핸들링 개선을 통한 생산성 향상
- 처음엔 "이렇게 진행될 것"이라고 예상한 단순한 순서도가 있었지만, 실제 로그 데이터를 보니 이벤트가 훨씬 복잡하게 얽혀있었음(설비 노후화, 레시피 변경, 소프트웨어 업데이트 등으로 원래 계획과 실제 순서가 계속 어긋남)
- 이 로그 데이터를 기반으로 패턴 분석을 해보니, **설비가 다운되기 직전에는 이벤트 패턴이 확 바뀌는 특징**을 발견 → 이걸 사전 예우(豫兆) 신호로 활용해서 문제 센서를 미리 교체하는 예지보전 적용
- 결과: **전체 생산시간 약 12% 절감**. "전체 공장에 100대의 장비가 있다면 88대로도 같은 생산을 할 수 있다"는 임팩트로 설명됨. 실제로 이 효과는 **장비 리스계약 해지/재판매**를 통해 직접적으로 검증됨

📷 [원본 슬라이드 참고 — 마이크론 프로젝트의 "개선전/개선후" 공정흐름 간트차트 비교 그림 (AtmArm_in→AirLock_in→...→AtmArm_out 경로). 개선 전후 시간축이 짧아진 걸 시각적으로 비교하는 핵심 그림]

반도체 장비 생산성 향상


• 마이크론 빅데이터 프로젝트

- 장비 내부 웨이퍼 핸들링 개선을 통한 생산성 향상



이렇게 진행된다 생각했지만....

실제 진행은!!!!



Convolutional AutoEncoder — 애매모호함을 파악하는 기술

정상 데이터는 풍부하지만 비정상(불량) 데이터가 희소한 제조 데이터의 특성상, 비정상을 직접 학습시키기보다 "정상"의 특징을 학습해서, 그 특징에서 벗어나는 정도로 비정상을 판별하는 방식이 자주 쓰임. 오토인코더(Encode → Compressed Data → Decode)로 정상 패턴의 특징을 압축해서 학습하고, 이 특징과 거리가 먼 데이터를 이상으로 잡아내는 원리.

디지털 장인(Digital Craftsman) — 이 강의의 하이라이트 개념

디지털 기술을 활용해 경험 많은 장인의 판단·능력을 구조화/시스템화한다는 개념. 아직 많은 산업 현장에서는 개개인의 수작업 판단(암묵지)에 의존하고 있음.

예시 1: 국내 글로벌 섬유업체 — 검사자가 "손바닥의 감각"으로 섬유 제품의 불량을 판별함.

예시 2: 국내 최대 타이어 회사 — 설비를 세팅할 때 청진기로 소음을 듣고 최적 셋팅을 판단함.

이런 아날로그 장인의 경험(소리를 듣고 "기어박스에 문제가 있군" 판단)을 **소음진동 도메인 지식 + 딥러닝 + 빅데이터**로 구조화하면, 디지털 장인은 "기어박스 고장 확률이 83%이며 시뮬레이션 결과 12.3시간 후 파손 확률이 93%"라는 식으로 **정량화된 판단**을 제공할 수 있게 됨.

 [원본 슬라이드 참고 — "디지털 장인 예시" 슬라이드. 아날로그 장인(청진기를 든 작업자 일러스트, "소리를 들어보니 기어박스에 문제가 있군")과 디지털 장인(딥러닝+빅데이터+소음진동 도메인 지식을 거쳐 "기어박스 고장이 83%이며... 12.3시간 후 파손 확률 93%임" 이라는 정량화된 결과를 내는 헬멧 쓴 작업자 사진) 대조 그림 — 이 강의 전체를 통틀어 "디지털 장인" 개념을 가장 직관적으로 보여주는 이미지라 꼭 캡처해둘 만함]


디지털 장인

- 디지털 기술을 활용하여 경험이 많은 장인의 판단과 능력을 구조화/시스템화
 - ✓ 아직 많은 산업 현장에서 개개인의 수작업으로 많은 작업이 진행되고 있음
 - ✓ 예1) 국내 글로벌 섬유 업체는 검사자가 “손바닥의 감각”으로 섬유 제품의 불량 판별
 - ✓ 예2) 국내 최대 타이어 회사는 설비를 세팅 시 청진기로 소음을 듣고 최적 셋팅
 - ✓ 발전된 센서 기술, 빅데이터, 인공지능 기술, 도메인 기술이 결합하여 불량 판별 및 최적 설비 세팅 가능 - 디지털화

디지털 장인 예시

기존 아날로그 장인

“소리를 들어보니 기어박스
에 문제가 있군”



디지털 장인

“기어박스 고장이 83%이며 시뮬레이션 해 보니
12.3시간 후에는 파손될 수 확률이 93%임”



17

17

정리 — 제조 AI 데이터의 특수성

강사가 강의 말미에 강조하는 포인트: 제조 데이터는 일반 데이터 분석(예: 금융권의 이상거래 탐지)과 다름. 금융권은 정상/비정상 데이터의 경계가 비교적 명확한 반면, **제조는 정상 데이터는 많지만 비정상 데이터가 극히 적어서 지도학습에 제약이 있음**. 대신 제조라는 도메인 특성을 파악해서 비지도학습을 하거나, 제조 도메인 지식을 지능(AI)과 결합시키는 접근이 필요하다는 게 결론. 다음 강의(7강)는 자율운영(Autonomous Operation) 파트를 다룬다고 예고함.

[7강] AI와 스마트 팩토리 (Part2) — 자동화 시스템

자동 반송 시스템이란

2강에서 배운 "제조시스템지식 + 자동화/연결화/지능화" 프레임워크를 다시 상기하면서 시작. **자동 반송 시스템(Material Handling System)**은 프로세스 설비와 설비 간의 이동을 자동화하는 것. 하지만 이는 단순한 물류 이동이 아니라 **언제 어떤 물건을 옮겨야 하는지를 알아야 하는 지능화의 영역**이기도 함 — 즉 자동화와 지능화가 겹치는 대표 영역.

자동 반송 시스템의 3가지 종류

1. **컨베이어 벨트** — 가장 간단하고 투자비 저렴. A에서 B까지 정해진 경로로만 나옴
2. **AGV(Automated Guided Vehicle)** — 지상에서 물건을 이동시키는 방식. 투자비 중/상. 최근엔 AMR(Autonomous Mobile Robot, 자율주행 형태)도 등장
3. **OHT(Overhead Hoist Transporter)** — 천장(위층)에서 물건을 옮기는 방식. 공장은 부지가 매우 비싸기 때문에(땅값뿐 아니라 클린룸 등 환경 유지비용도 큼) 상부 구조를 활용해 공간을 절약하는 기술. 반도체 공장의 대표적 물류 장비이며, "택시"에 비유됨 — 목적지를 지정하면 자동으로 와서 물건을 싣고 목적지까지 데려다줌

왜 AI가 필요한가 — 반도체 공장의 규모 문제

반도체 공장은 100% 자동화되어 있고(사람이 물건을 직접 나르는 경우는 거의 없음, 문제 있을 때만 카트로 "푸비/웨이퍼 라시" 이동), **메모리 반도체 기준 300~500개 스텝**, 투입부터 산출까지 한 달 넘게 걸리는 복잡한 공정. 나노 공정으로 미세화될수록 불확실성은 더 커짐. 강사 본인이 반도체 공장 오퍼레이션을 담당했을 때 스스로를 "소방서"라고 표현했을 정도로, 예측 못한 일이 늘 발생해서 계속 불을 꺼야 하는 업무였다고 회고함.

규모의 문제: 최신 반도체 팹은 **1000대 이상의 OHT 운영**을 요구함. 이 정도 규모에서는 사람이 상황별로 임기응변으로 대응하는 방식이 아예 불가능함.

"혼잡"을 어떻게 정의할 것인가 — 룰 기반의 한계

기존 방식은 "혼잡이 생기면 우회하라"는 식의 **룰 기반**으로 대응해왔음. 그런데 "혼잡"이라는 개념 자체를 수치로 정의하는 게 애매함:

- 단위면적당 OHT가 몇 대 이상이면 혼잡인가? 5대면 정상, 8대면 혼잡이라 치면, 왜 7대는 혼잡이 아니고 8대는 혼잡인가?
- 속도 기준으로 봐도 마찬가지로 — 1.4초는 정상, 1.5초는 혼잡이라는 경계가 임의적임

게다가 공장은 계속 변하는 "살아있는 생명체" 같아서, 한번 정해놓은 룰이 장비 고장이나 물동량 변화가 생길 때마다 계속 바뀌어야 하는데 이걸 사람이 매번 대응하기 어려움.

Automation → Autonomous — 자동화에서 자율화로

물류 혼잡 대응, 고장 상황 대응을 기존의 "사람이 건별로 수작업 대응"하는 방식으로는 1000대 이상 규모에서 불가능. 그래서 카이스트가 다임리서치(DAIM Research)라는 기업과 함께 **강화학습**을 적용해서 **자동화(Automation) → 자율화(Autonomous)**로 나아가는 시스템을 개발함.

강화학습과 알파고

강화학습은 "환경에 대한 반응으로 학습(Learning)하는 시스템". 알파고로 대중에게 유명해짐. 강사가 이 개념을 **자전거 타기 배우는 것에** 비유: 자전거를 탈 때 "5도로 기울면 핸들을 15도 꺾고 오른발에 36.5뉴턴을 가한다" 같은 수치로 배우는 게 아니라, 이렇게 저렇게 해보면서 **감을 익히는 것**과 같은 원리라는 것.

아타리 브레이크아웃 학습 데모  (강의자료 상 동영상, 스크립트에도 비슷한 취지로 언급): 처음 학습이 안 된 상태에선 AI가 그냥 왔다갔다만 하며 잘 못함(사람이 룰을 만들어준 것보다도 못함). 그런데 **10분 학습 후엔** 어느 정도 패턴을 익히고, **240분 학습 후엔** 인간 고수 수준을 넘어 벽을 뚫는 "터널링" 전략처럼 초고수만 아는 효율적인 전략을 스스로 발견하는 수준까지 발전함. 이게 강화학습의 힘이라는 걸 보여주는 예시.

 [원본 슬라이드 참고 — 아타리 브레이크아웃 강화학습 데모 영상 스틸컷(10분 학습 vs 240분 학습 비교). 강화학습의 성장 과정을 시각적으로 보여주는 유명한 데모]



카이스트 OHT 제어 알고리즘 — Q-Learning

카이스트가 다임리서치와 함께 개발한 Q-Learning 기반 OHT 제어 알고리즘(논문: Ilhoe Hwang, Sang Pyo Hong, Young Jae Jang, Sunil Kim and In-Ho Moon, "System Design and Development of the Q-Learning Based Overhead Hoist Transport (OHT) for Semiconductor Fabs," 24th International Conference on Production Research, 2017, Poland).

결과 비교: 기존 산업계에서 쓰는 알고리즘은 상승 정체구간이 계속 발생하는 반면, 카이스트가 개발한 Q-Learning 기반 알고리즘은 **상승 정체구간이 거의 없이 모든 구간이 원활하게 진행됨**.

 [원본 슬라이드 참고 — 반도체 공장 레이아웃 시뮬레이션 상에서 "기존 알고리즘(산업계 활용)"과 "KAIST개발 Q-Learning 기반 알고리즘"의 물류 흐름을 비교한 그림. 정체구간이 빨간 원으로 표시된 기존 방식과, 정체 없이 원활한 KAIST 방식이 나란히 비교되어 한눈에 차이를 보여주는 자료]

Simulation Validation – Large Case

• Conventional approach



상습 정체구간 발생


Copyright © Young Jae JANG

17

ISysE
Industrial & Systems Engineering

Simulation Validation – Large Case

카이스트 개발 알고리즘 - 상습정체 구간이 없음 - 모든 구간 늘 원활히 진행...



Copyright © Young Jae JANG

18

ISysE
Industrial & Systems Engineering

18

마포대교 비유 — 예측 못한 상황에서의 자율 대응 실험

카이스트팀이 재미있는 실험을 진행함: 시뮬레이션 상에서 인위적으로 특정 구간의 통행을 갑자기 중단시켜봄(강사의 비유 — "마포대교 통행을 갑자기 막아버린 상황"). 이때:

- 사람이 개입해서 교통통제를 하는 경우: 우회시켜도 이동시간이 급격히 증가(엄청난 혼잡 발생)
- 카이스트가 개발한 알고리즘: 사람 개입 없이 스스로 "마포대교가 막혔으니 나는 이쪽으로, 너는 저쪽으로" 하는 식으로 스스로 판단해서 한쪽으로 몰리지 않게 분산 이동

→ 사람이 개입해도 못하는 걸 AI가 자율적으로 더 잘 해낸다는 걸 보여주는 실험 결과.

조지아텍(Georgia Tech) 벤치마크 비교

OHT routing 연구에서 100대 이상 규모로 실제 구현한 연구는 조지아텍(Georgia Tech)이 2012~2014년에 진행한 연구가 **현존하는 유일한 벤치마크**였다고 언급됨. 조지아텍 방식은 AI가 아니라 **CPU 연산을 통한 빠른 계산**(수학적 최적화)으로 문제를 풀었음.

비교 결과:

- 기존 산업계 방식: 물동량이 늘어날수록 **평균 이동시간이 기하급수적으로 증가** (사용 불가 수준)
- 조지아텍 방식: 산업계보다 낮지만, 역시 물동량이 늘면서 계속 증가
- 카이스트 방식: 물동량이 늘어나도 **거의 플랫폼(평탄)**하게 안정적으로 유지됨

연산 시간 비교: 조지아텍 방식은 매 이동마다 계속 연산을 해야 해서 CPU 연산시간이 0.5초 수준이면 1000대 이상 규모에선 감당이 안 됨. 반면 카이스트 방식은 **강화학습으로 미리 학습된 "메모리(감)"**를 활용하기 때문에 실시간 연산이 거의 필요 없음 — 자전거 탈 때 매번 논리적으로 생각하지 않고 "감"으로 타는 것과 같은 원리. 그 결과 **연산 속도가 10배 빠름**. 카이스트는 이 기술을 실제로 사업화에 성공했다고 언급됨.

자동 물류 반송 시스템의 진화 — Mass Production에서 Mass Customization으로


과거 컨베이어 방식은 한번 만들어놓으면 그 경로를 그대로 따라야 해서 **다품종 소량생산에는 부적합**했음. AGV가 스마트 팩토리에서 많이 쓰이는 이유는, AGV가 부품을 들고 필요한 곳을 알아서 찾아다닐 수 있기 때문. 자동차 산업도 이런 방향으로 바뀌고 있음 — 기존엔 컨베이어벨트가 지나가면서 조립했다면, 이제는 **AGV가 차체를 들고 필요한 작업장을 돌아다니는 방식**(Mass Customization, 대량 맞춤 생산)으로 진입 중.

아우디(AUDI) 모듈러 어셈블리 사례 (강의자료): 기존 컨베이어벨트 라인을 해체하고, 부품/자재가 주체가 되어 기계·설비들이 부품을 지원하는 형태로 전환. 중앙 컴퓨터가 문 설치 스테이션에 병목이 생긴 걸 인식하면 다른 빈 스테이션(트렁크 패널 등)으로 재배치하는 driverless transport system을 사용함.

 [원본 슬라이드 참고 — 아우디 모듈러 어셈블리 사진(기존 컨베이어벨트 자동차 조립라인 vs 기존 AGV 시스템 vs 모듈러 어셈블리 개념도 3단 비교). 자동차 산업의 생산방식 패러다임 변화를 보여주는 실사진]

에이전트 기반 “미션 중심” 군집 AGV 로봇 개발 (Agent based Mission Oriented Fleet AGV Robot)

- AUDI - Modular assembly
 - The transport of the car bodies and components between the stations in modular assembly is taken over by **driverless transport systems**
 - The routines in modular assembly are highly flexible with regard to time and space
 - When the central computer recognizes a jam at a station for installing doors, it can often redirect it to another vacant station(trunk cladding)



"각자도생"에서 "공생공존"으로: 강사가 마무리하며 강조하는 메시지 — 지금까지 많은 로봇들이 산업 현장에서 사람의 일을 대신하고 있지만, 대부분은 지시받은 업무를 수동적으로 단순 반복하며 자신의 일만 처리하는 "낮은 지능"의 로봇들이었음. 이 로봇들이 서로 영리하게 협업하며 작업한다면 생산성을 몇 배로 올릴 수 있다는 것 — "각자도생(各自圖生)"에서 "공생공존(共生共存)"으로의 패러다임 전환.

[8강] 디지털 트윈

디지털 트윈이란 — 스크린골프와 내비게이션 비유

디지털 트윈은 이미 우리 생활에 깊숙이 들어와 있는 개념이라며 두 가지 친숙한 비유로 설명함.

스크린골프: 실제로 골프채를 휘두르고 공을 맞추는 행위는 현실(물리적 공간)에서 일어나지만, 그 이후 공이 날아가는 넓은 필드는 가상 공간으로 구현됨. 물리적으로 한정된 실내 공간을, 연동된 가상 공간으로 확장하는 개념.

카이스트 연구실 안에도 실제 AGV 2대, OHT 5대만 물리적으로 돌아가지만, 이를 시뮬레이션과 연동시켜서 실제로는 1000대 규모가 운영되는 것처럼 확장해서 실험함 — 스크린골프와 같은 원리.

내비게이션(Navi): 목적지를 설정하면 계속 길을 안내해주는데, 이때 사용자는 실제 도로를 가고 있지만 **가상 환경(지도 앱) 속에서도 동시에 길을 가고 있음**. GPS 데이터로 현실 데이터가 가상현실로 전송되고, 가상에서 동기화(싱크)해서 지금 가고 있는 경로와 남은 거리를 알려주는 것.

시뮬레이션과 디지털 트윈의 차이

- **시뮬레이션:** 현실을 보고 그걸 모사해서 가상환경을 "한번" 만들어놓는 것. **실시간으로 연동되지 않음** — 독립적으로 움직이는 시뮬레이터
- **디지털 트윈:** 센서를 연결시켜서, 현실에서 돌아가는 것과 **실시간으로 연동**시키는 것

과거엔 통신 기술의 한계로 이런 실시간 연동이 어려웠지만, IoT/센서/통신 인프라가 갖춰지면서 디지털 트윈이 가능해졌다는 게 핵심.

디지털 트윈이 필요한 이유

1. **제한된 공간의 확장** — 스크린골프처럼 물리적으로 한정된 공간을 가상으로 확장
2. **더 나은 정보 제공** — 내비게이션처럼 현재 상황을 효율적으로 전달
3. **시간과 공간의 확장** — 지금 눈앞에 보이는 것 이상으로 더 넓은 환경과, 몇 시간 앞선 미래까지 확장해서 볼 수 있음

시뮬레이션 방식의 3가지 유형

- **Virtual(가상):** 100% 컴퓨터 환경에서만 이루어지는 일반적인 시뮬레이션
- **Constructive(구성적):** Virtual과 Live를 섞은 것 — 실제 공간과 가상 공간을 연결
- **Live(실사):** 가상의 시나리오를 만들어놓고 실제로 훈련하는 것 (예: 군사훈련)

시뮬레이션 모델도 두 가지로 구분됨:

- **수치 시뮬레이션(Numerical):** 미분방정식 등으로 물리 현상을 계산 (예: 열전도 계산)

- **이벤트 기반 시뮬레이션(Event-based):** 특정 사건이 일어나는 순서와 상관관계를 분석해서, 각 이벤트를 시나리오로 연결

시뮬레이션 활용 사례 : 공장 건설 전 레이아웃 검증/Capa 분석, 물량 투입 전 사전 가동률 및 지표 파악, 다양한 시나리오 분석 (고객 주문 분석, 시장 분석, 비상상황 대비 분석)

시뮬레이션의 한계와 디지털 트윈의 등장

시뮬레이션의 근본적 한계: **만들어진 시뮬레이션과 현실 사이엔 항상 괴리가 있고, 한번 구축되면 현실 상황과 분리됨**. 이 한계를 극복하는 방법은 두 가지:

1. 현실과 100% 똑같은 시뮬레이션을 구현 — **사실상 불가능**
2. 현실과 계속 연동시켜서 지속적으로 보정 — 이게 바로 **디지털 트윈**

즉 디지털 트윈은 "가상현실과 현실세계 시뮬레이션이 통신을 통해 서로 연동함으로써 기존 시뮬레이션의 한계를 극복한 것"이라는 정의.

5개 영화의 공통점 — 기억(정체성)의 조작

장사가 흥미로운 퀴즈를 냄: 블레이드 러너, 공각기동대, 토탈 리콜, 이터널 선샤인(원문 "인터내셔널"으로 음성인식됨 — Eternal Sunshine of the Spotless Mind로 추정), 메멘토(크리스토퍼 놀란 감독) 이 5개 영화의 공통점은?

정답은 **"기억"** — 모두 기억이 조작되는 이야기임:

- 블레이드 러너: 인조인간에게 과거 기억이 주입되어 자신을 사람이라 믿음
- 공각기동대: 사람의 기억을 해킹해서 다르게 조작(예: 존재하지도 않는 딸이 피아노 대회에서 우승했다는 기억)
- 토탈 리콜: 정의로운 사람이라 믿었던 주인공이 알고 보니 기억이 조작된 악당이었음
- 이터널 선샤인: 헤어진 연인과의 아픈 기억을 지우는 기술
- 메멘토: 단기 기억상실증 환자가 문신으로 기억을 기록하지만 범죄조직에 이용당함

장사가 이 비유를 든 이유: **강화학습으로 만든 지능도 결국 "훈련을 통해 배가된 지능"**이라는 점을 강조하기 위함. 처음엔 지능이 전혀 없는 로봇을 "공장에서 10년만 써보면 학습해서 좋아질 것"이라며 그냥 투입할 수는 없는 노릇 — 그래서 **가상현실(디지털 트윈)에서 먼저 훈련시켜서, 그 학습된 지능(=조작된/주입된 기억)을 현실의 로봇에 "이식"**시키는 방식이 쓰인다는 것. 영화 속 인조인간이 기억을 주입받듯, 실제 로봇도 가상환경에서 학습한 지능을 이식받는다는 절묘한 비유.

LCD/OLED 반송 크레인 사례


LCD/OLED 공장에서 스택커(stacker)가 여러 작업을 하는데, 하나의 레일에 두 대의 크레인이 왔다갔다 해야 해서 **충돌 회피**를 위해 사람이 "공동구역"을 미리 정해두고 하나씩만 들어가게 하는 방식으로 운영했음 — 굉장히 비효율적.

카이스트의 아이디어는 이 공동구역 자체를 없애고 **스마트하게 충돌을 피하면서 작업하는 AI 알고리즘**을 구현하는 것. 이 문제는 수학적으로 **외판원 순회 문제(Traveling Salesman Problem, TSP)**에ダイ나미한 환경, 두 대의 크레인이 동시에 움직이는 조건까지 더해진 매우 어려운(NP-hard) 문제였음.

해결 방식: 문제를 잘게 쪼개서 쉬운 문제로 구조화하고 학습시킨 뒤, 가상환경에서 학습한 지능을 실제 크레인에 이식함. 그 결과 이동거리(이동반경)가 넓어져 속도를 확 늘릴 수 있게 됨. **가상환경에서는 10년치 훈련도 압축해서 몇 시간 만에** 끝낼 수 있고, 이 학습된 지능을 현실에 이식하면 "10년 동안 일한 것처럼" 효율적으로 작업하는 크레인이 됨.

디지털 트윈의 진짜 힘: 현실을 100% 싱크한 시뮬레이션은 불가능하므로, 현실에서 작업하다가 "배웠던 것과 조금 다르다"는 차이가 생기면 그 파라미터를 수정해서 **가상환경에서 급속하게 재학습**시키고, 그 학습 결과를 다시 실시간으로 현실에 반영함. 현실과 가상이 계속 실시간 연동되며 지능을 배가시키는 구조. 유사하게 공장 엘리베이터 같은 것도 이 알고리즘으로 테스트/실험 중이라고 언급됨.

 [원본 슬라이드 참고 — "디지털 트윈 + AI" 다이어그램(Simulated System ↔ Digital Twin ↔ Real System, Off-line Learning/On-line Learning 화살표). 가상-현실 간 지능 이식 구조를 명확히 보여주는 핵심 그림. L사 POC에서 기존 대비 20% 이상 효율 증진 검증 완료라는 문구도 있음 



기존 알고리즘 (산업계 활용)

AR/VR과 디지털 트윈 — 유지보수 활용

스마트 디바이스(AR/VR 글래스)를 착용하면 실제 설비 위에 가상 정보를 겹쳐 볼 수 있음. "지금은 이렇게 움직여야 하는데 왜 저렇게 움직이지?"를 실제-가상을 함께 보며 판단할 수 있고, 장비가 고장났을 때 과거 몇 시간 동안의 상태를 가상으로 플레이백해서 문제를 진단할 수도 있음. 현장에서 보는 화면을 실시간 스트리밍해서 다른 지역의 엔지니어와 공유하며 토론도 가능 — 이런 솔루션을 카이스트가 스타트업(Zinnotech 등)과 함께 개발 중 **NEW**.

DEMO 사례 **NEW**(강의자료): 필드의 실제 시스템 → 3D 홀로그래픽 애니메이션으로 작업 지시 전달 → 현장 엔지니어가 AR로 실행 → 본사 전문가들과 ERP/PLM/제품설계 정보를 교환하며 의사결정하는 사이클 구조.

[원본 슬라이드 참고 — AR 글래스를 착용한 작업자가 실제 배관·설비 위에 가상의 파란색 3D 오버레이(파이프 경로 등)를 보며 태블릿으로 확인하는 사진. AR+디지털트윈의 실제 현장 적용 모습을 직관적으로 보여주는 이미지]



스마트 매뉴얼 / 스마트 리모트 솔루션 NEW: 3차원 홀로그래픽 이미지 기반 조립공정 교육(SmartManual) — 단계별 3D 모델 가이드, 다양한 콘텐츠(CAD, 이미지, 텍스트, PDF)를 인터랙티브 3D 매뉴얼로 제공. 그리고 지식을 가진 전문가와 현장 작업자 간 극을 해소하는 원격 협업 솔루션(SmartRemote) — AR/MR 기반 화상통화로 3D 모델을 실시간 공유하며 원격 트러블슈팅.

정리

디지털 트윈의 정의와 시뮬레이션으로부터의 진화 과정, 디지털 트윈+AI 사례(OHT/크레인 강화학습 이식), 디지털 트윈+AR 사례(스마트 매뉴얼/리모트)를 다룸. 이 강의 시리즈 전체를 통틀어, 스마트 팩토리는 결국 "제조 시스템의 본질 이해(F=MA, 리틀의 법칙, 큐잉이론) + 자동화/연결화/지능화의 시너지 + 이를 가속화하는 AI/디지털트윈 기술"이 삼박자로 맞아야 완성된다는 메시지로 시리즈가 마무리됨.

🗨️ 정리하며 (팀 스터디용 포인트)

- **캡스톤/경진대회에 바로 써먹을 수 있는 프레임:** "문제 정의 → 왜 현재 방식이 비효율적인지(룰 기반의 한계, 애매모호한 기준의 문제) → 데이터/AI로 어떻게 정량화·자동화·지능화할 것인지"의 흐름은 거의 모든 제조/물류/최적화 관련 프로젝트에 그대로 적용 가능한 스토리 구조임. 특히 "자동화 vs 지능화" 구분과 "왜 이 방법이 필요한가"를 먼저 설명하는 방식은 발표 스토리텔링에 유용해 보임.
- **리틀의 법칙(WIP = CT × TH)**은 제조/물류/서비스 도메인 어디든 재공·대기·처리량 관계를 설명할 때 바로 쓸 수 있는 아주 범용적인 도구. 캡스톤 프로젝트에서 병목·대기시간 분석을 다룰 때 이 프레임을 언급하면 이론적 근거를 가진 것처럼 보일 수 있음.
- **HP 사례(버퍼 제거의 함정)**는 "무조건 낭비를 없애는 게 능사가 아니다"라는 반직관적 인사이트라 발표 자료에서 임팩트 있게 쓸 수 있는 케이스임.
- **GAN 기반 불량 데이터 증강, AutoEncoder 기반 이상탐지(비지도학습)**은 실제 제조 데이터(불균형 데이터) 문제를 다룰 때 방법론적으로 참고할 만함 — 캐글 등에서 클래스 불균형 문제를 다룰 때도 같은 논리 적용 가능.
- **디지털 장인** 개념은 "AI가 사람을 대체한다"보다 "사람의 암묵지를 정량화/구조화한다"는 프레이밍이라 팀 프로젝트 소개할 때 설득력 있는 워딩으로 활용 가능해 보임.

📎 참고 — 강의자료에만 있던 내용(NEW) 모아보기 + 확인 필요 사항

- 0강 프리뷰 사례(웅진케미칼, 마이크론, S중공업)는 스크립트에서 구체적으로 설명되지 않음 — 6강(마이크론), 8강(디지털 트윈) 본문에서 실제로 다뤄짐을 확인함
- 큐잉이론의 수학적 근사식(변동계수 c_a , c_e 포함), 일본 단팔뿔 공장 영상 과제는 강의자료 전용
- 생산거점 최적화 사례(스마트폰 생산기업, 26% 비용절감), WIP/스케줄링 최적화 수식은 강의자료 전용
- 아우디 모듈러 어셈블리 사례, "디지털 트윈+AI" L사 POC 20% 효율 증진, AR 데모/스마트매뉴얼·스마트리모트 솔루션(Zinnotech)은 강의자료 전용
- ⚠️ **확인 필요:** 3강(1강 본문)에서 언급된 자동차 리콜 사태는 음성 인식상 "돌타, 브레이크 사태"로 표기되어 있어 정확한 회사명이 불명확함. 문맥상(2000년대, 브레이크 관련 대규모 리콜) 도요타의 리콜 사태로 추정되나, 원본 음성이나 강의자료로 재확인 권장
- ⚠️ 5강 A/B 제품 영업이익 개선 수치는 스크립트 음성상 "9.5% 정도, 근한 10%"로 언급됐고 강의자료 손글씨 메모에는 "9.5%"로 적혀있어 9.5%가 정확한 수치로 보임