

제 6회 KAMP 경진대회 준비사항

주제 : 제조 AI 데이터셋을 활용해 장비 이상 조기탐지, 품질 이상 탐지 및 진단, 공정 운영 최적화 등 제조현장 문제를 해결하는 AI 모델 제작

1. KAMP 데이터셋 3 종 정도를 미리 풀어보기

- 특히 품질 이상탐지, 설비 이상탐지, 공정 최적화를 각각 하나씩 골라서 연습
- KAMP 가 공개한 가이드북 자체가 문제 정의 → 데이터 이해 → 전처리 → 알고리즘 선택 → 학습 → 튜닝 → 평가 → 해석 구조로 되어 있어서 사실상 경진대회 연습 교재로 쓰기 좋음

2. 범용 경진대회 Notebook 을 미리 하나 만들기

- 데이터가 공개되면 처음부터 코딩하는 게 아니라 load → info/describe → 결측/중복 → target 확인 → 분포 시각화 → 상관관계 → leakage 검사 → baseline → CV → feature importance → tuning → submission 까지 셀을 만들어 두기
- 분류용으로는 Logistic/RandomForest → LightGBM/XGBoost/CatBoost, 회귀면 RandomForest/ExtraTrees → XGBoost/LightGBM/CatBoost 순으로 바로 비교할 수 있게 만들어 두면 됨

3. 제조 데이터에서 제일 먼저 Data Leakage 를 의심하기

- 예를 들어 불량 여부를 예측하는데 불량 검사 이후에 생성되는 컬럼이 들어가 있거나, 같은 제품·LOT·설비 데이터가 train/validation 양쪽에 들어가면 점수가 비정상적으로 높아짐
- 특히 `lot_id`, `machine_id`, `timestamp`, `product_id` 가 있으면 일반적인 random split 부터 하지 말고 **시간 기준 split / GroupKFold / 설비 단위 split** 가능성을 먼저 보는 것이 실제 대회에서 상당히 중요

4. 제조 특화 Feature Engineering 을 준비

- 센서 데이터라면 단순 원본 값보다 rolling mean/std/min/max, 변화량(diff), 직전 대비 변화율, 센서 간 비율, 정상범위 초과 횟수, 공정단계별 평균, 제품/설비별 편차, 최근 N 개 측정값 통계가 강함.
- 시계열 센서라면 lag 1/3/5/10 이나 rolling window 를 만들되 미래 데이터를 끌어오는 leakage 는 반드시 막아야 함

5. 평가지표별 전략을 따로 준비

- Accuracy 만 보고 있으면 위험함
- 불량품이 3%밖에 없는 데이터면 전부 정상이라고 해도 Accuracy 97%가 나오기 때문
- 분류라면 Accuracy, Precision, Recall, F1, ROC-AUC, PR-AUC 를 같이 보고, 특히 제조 이상탐지는 **False Negative**, 즉 실제 불량/고장을 정상이라고 판단하는 경우의 비용을 따져야 함.
- 회귀라면 MAE/RMSE/MAPE 를 비교하고 이상치 영향을 확인

6. 점수 경쟁과 발표 경쟁을 동시에 준비

- 이 대회는 과거에도 서면평가 후 모델 구축과정 발표평가를 진행한 방식이었기 때문에, 최종 모델만 남기지 말고 Baseline 0.81 → Feature 추가 0.84 → CatBoost 0.87 → tuning 0.88 처럼 실험 기록을 계속 남기는 게 좋음.
- 모델 성능뿐 아니라 **“이 모델을 공장에 적용하면 무엇이 줄어드는가?”**를 설명할 수 있어야 함.
- 예를 들어 “불량 검출 정확도 95%”보다 **“공정 완료 후 검사하는 방식에서 생산 중 이상징후를 탐지해 재작업·폐기 가능성을 사전에 줄인다”**가 제조 AI 프로젝트다운 설명